论文精读海报 | Sensor-Language Foundation Model

SensorLM: 可穿戴传感器信号的语言语义建模

核心观点：先用层级 caption 构造 sensor-text pair，再联合训练 sensor encoder、text encoder 与 multimodal decoder，使传感器表示支持识别、检索与生成。

对方向一的价值：从“手机 IMU 短窗口分类”走向“人体动作、手机运动、场景语义联合表示”。注意：它不能直接替代标准 HAR 监督分类器。

1. 问题定位

传统 HAR 多是封闭类别分类：**sensor -> activity label**。SensorLM 转向更开放的目标：**sensor -> language-understandable representation**。

zero-shot | few-shot | retrieval | captioning

2. 数据形态

26 x 1440
一天级分钟特征矩阵

103K+
Fitbit / Pixel Watch 用户规模

59.7M h
大规模真实世界 wearable 数据

127
覆盖国家和地区

包括 PPG、三轴加速度、海拔、皮温、EDA 等；不是 UCI HAR 的 **128 x 9** 短窗口原始 IMU。

3. 层级 Caption 构造

Statistical 数值摘要
用 mean / max / min / std 等统计量模板化描述总体水平。

Structural 时间结构
检测 increase / decrease / stable / spike / drop，描述局部变化。

Semantic 活动语义
从活动、睡眠、mood 事件记录生成文本，例如 Walk、Outdoor Bike、Sleep。

关键判断：caption 是弱语义监督，不是逐窗口精确 HAR 标签。

4. 方法主线：先构造配对，再联合预训练

Sensor Matrix X_i -> Caption Text T_i -> Sensor-Text Alignment -> Recognition Retrieval Generation

Sensor Encoder

- ViT-style 2D patches
- 2 features x 10 min -> 1872 tokens
- Transformer 捕获局部与长程依赖

Text Encoder

- 输入 tokenized caption
- 输出 pooled text embedding
- 向 decoder 提供文本侧表示

Contrastive Flow

- sensor/text 分别 pool、project、normalize
- 匹配 pair 拉近，非匹配 pair 拉远
- 支撑 zero-shot 分类与跨模态检索

Generative Flow

- decoder 使用 causal mask
- cross-attention 读取 sensor tokens
- 预测下一个 caption token

```
L_SensorLM = lambda_con L_contrastive + lambda_cap L_captioning
```

5. 三种模型变体

范式	训练目标	擅长	局限
CLIP-like	只用对比损失	zero-shot、sensor-text retrieval	不能生成文本
Cap-like	只用生成损失	sensor caption generation	embedding 对齐弱，zero-shot 差
CoCa-like	对比 + 生成	兼顾识别、检索、生成	结构和训练成本更高

直接启发：分类/检索主要依赖 contrastive alignment；自然语言解释需要 captioning objective。

6. 下游任务如何连接 HAR

Zero-shot Activity Recognition

候选活动写成 prompt，经 text encoder 得到 label embedding；与 sensor embedding 比相似度。

Few-shot / Linear Probing

冻结 sensor encoder，只用每类少量标签训练线性分类器，评价 label efficiency。

Sensor-Text Retrieval

sensor 查 caption，或 caption 查 sensor；R@K 表示正确配对是否进入前 K 名。

Caption Generation

给定 sensor 自回归生成文本；用于解释，不等同于精确动作标注。

7. 主要结果怎么读

Zero-shot 20 类活动识别

方法	AUROC	F1	BACC
Gemma-3-27B	**0.50**	**0.01**	**0.05**
Gemini 2.0	**0.51**	**0.03**	**0.07**
SensorLM	**0.84**	**0.29**	**0.31**

Few-shot Activity AUROC

LABELS/CLASS	SIMCLR	SENSORLM
5	**0.54**	**0.73**
10	**0.55**	**0.79**
20	**0.58**	**0.83**
50	**0.60**	**0.88**

关键消融

设置	ZERO-SHOT AUROC	结论
statistical	**0.51**	几乎无活动语义
structural	**0.50**	趋势不等于类别
semantic	**0.71**	活动事件是关键
structural + semantic	**0.84**	整体最好

8. 必须保留的限制

- 不是 UCI HAR 式短窗口原始 IMU；输入是一整天 26 维分钟级特征。
- semantic caption 来自事件记录和模板生成，存在噪声与覆盖不足。
- 没有在标准监督 HAR benchmark 上直接和 1D CNN / LSTM 比准确率。
- Zero-shot AUROC 高，但 F1 / BAcc 仍不是成熟分类器水平。
- 2D patch 依赖 feature 顺序，迁移到手机 IMU 时需重设通道组织。

9. 对后续研究的结论

1. **短期不能直接复现。** 当前阶段更适合作为方法路线参考。
2. **中期可借鉴对齐目标。** 手机 IMU 可与动作文本、视频事件或运镜语义做 contrastive alignment。
3. **长期价值在开放语义。** 对“边走边拍摄、镜头上扬、场景切换”等组合行为更有意义。
4. **下一篇看 SensorLLM。** 它更接近短窗口 motion sensor 与 HAR 设定。

Paper: SensorLM: Learning the Language of Wearable Sensors | arXiv:2506.09108