论文精读海报 | HAR / HAS / HAF Unified Modeling

P2LHAP：Patch-to-Label Seq2Seq Transformer

面向可穿戴传感器连续数据流，同时完成活动识别、活动分割与活动预测。核心不是把一个固定窗口分类，而是把多通道传感器流切成 patch 序列，并输出 patch-level activity label sequence。

对方向一的直接价值：它提供了“未来延续概率/切换趋势”的更系统输出形式。先预测未来 patch 标签序列，再派生延续、切换、下一状态和首次切换位置。

1. 问题动机：三个任务统一

传统方法常把 HAS、HAR、HAF 分开建模，或用共享编码器加多个任务头。P2LHAP 改为用一个 Seq2Seq 标签序列输出统一三者。

- **HAS** Activity Segmentation：从连续流中确定每段活动的起止边界。
- **HAR** Activity Recognition：给每个 patch 或活动段赋予活动类别。
- **HAF** Activity Forecast：预测未来若干 patch 的活动标签序列。

2. 数据与输入形状

`X_{1:L}`	M 维连续 wearable sensor sequence；每个时刻 x_t 属于 R^{1 x M}。
`y_{1:L}`	每个采样点对应活动标签；最终转成 patch-level labels。
`P, S`	patch length 与 stride；默认 P=10, S=10，可 overlap 或 non-overlap。
`B x M x L`	batch 中的多通道序列；按通道独立切分 patch。
`(B*M) x P x N`	reshape 后送入 Transformer；N = floor((L-P)/S)+2。

注意：论文不是完全取消长度超参数，而是不再假设一个固定滑窗就是一个完整活动。

3. 数据集与默认设置

WISDM
29 人，裤袋手机三轴加速度计，20 Hz，6 类日常活动；论文用线性插值填补缺失值。

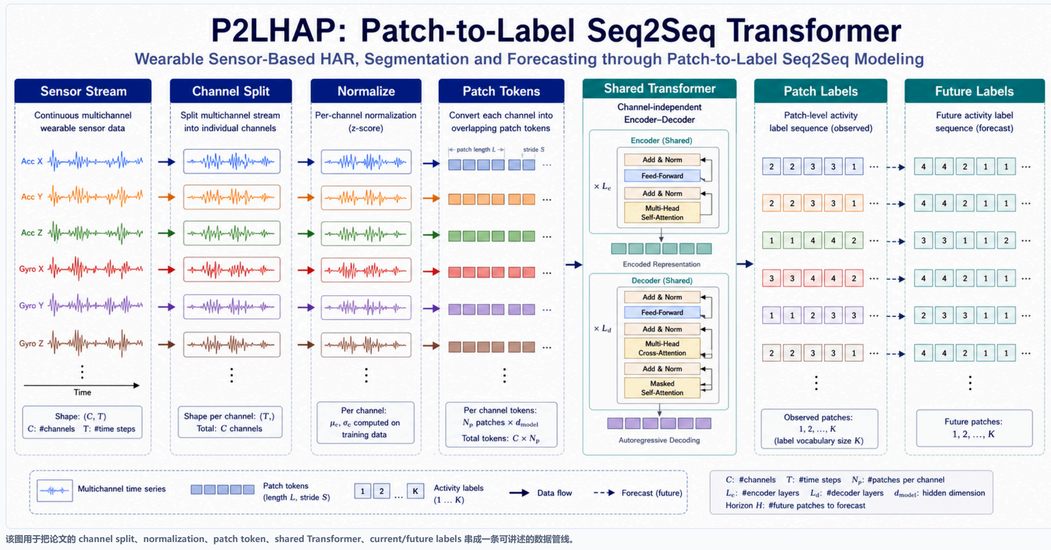
PAMAP2
9 人，胸/手/踝 IMU，100 Hz；加速度、角速度、磁力计；12 个必做活动 + 6 个可选活动。

UNIMIB SHAR
30 人，Samsung 手机 Bosch BMA220，50 Hz；11,771 段，17 类活动：9 类 ADL + 8 类跌倒。

0.7/0.1/0.2 train / validation / test	**pred_len=8** future patch label horizon
6 layers encoder-decoder layers	**8 heads** default attention heads

4. 方法数据流：Patch-to-Label Seq2Seq

Imagegen 图：模型数据流 — sensor stream -> patch tokens -> labels



该图用于把论文的 channel split、normalization、patch token、shared Transformer、current/future labels 串成一条可讲述的数据管线。

A. Patching

- 每个 sensor channel 独立处理。
- 先归一化，再切成长度 P 的 patch。
- patch 作为 Transformer token，而不是单点或完整活动窗口。
- 短事件可由多个 patch 捕获，长活动可包含任意数量 patch。

B. Channel Independence

- 每个 patch 只含单一传感器通道信息。
- 不同通道共享 embedding 与 Transformer 权重。
- 目标是减少多变量互相干扰并控制参数规模。
- 类似 PatchTST 在时间序列预测中的设计思想。

C. Encoder

- linear projection: patch block -> D 维 latent space。
- learnable positional encoding 保留 patch 时序位置。
- multi-head attention + BatchNorm + FFN + residual。
- 输出每个通道的 patch-level latent representation。

D. Decoder + Head

- decoder 结合 encoder representation 与 patch-level sensor data。
- 用 K/Q/V attention 生成 z' 表示。
- Flatten + Linear + Softmax 输出 patch activity labels。
- 同时输出未来长度 T_pre 的 label sequence。

```
z' = softmax(Q^T K / sigma) V
y_hat = argmax(softmax(Linear(z')))
y_pre = { y_hat_{L+1}, ..., y_hat_{L+T_P} }
```

5. 训练目标与平滑策略

Patch Classification Loss

对每个 patch 的预测标签与真实标签做 Softmax CrossEntropy，并考虑类别不均衡下的有效样本权重。

```
L_cls = l_p(y_hat, y)
```

Forecast Loss

根据未来 patch activity label sequence 与 ground truth future labels 计算预测损失。

```
L_pre = l_p(y_hat_pre, y_gt)
```

Smoothing Loss

使用 truncated MSE 约束相邻 patch 的类别概率变化，减少过度分割。

```
L_seg = LT-MSE
Delta_t,c = |log y_t,c - log y_{t-1,c}|
tau = 2
```

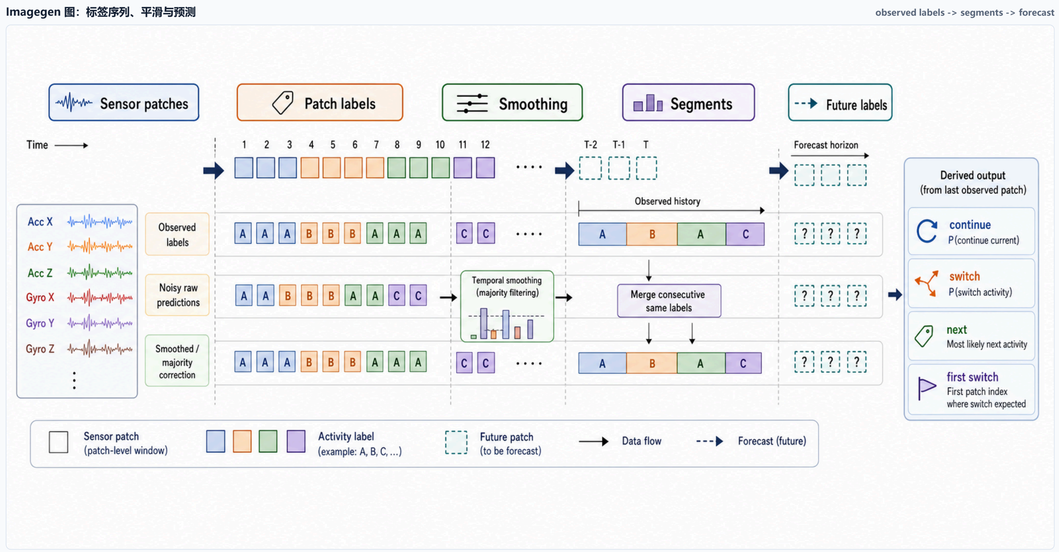
总目标

训练时联合优化当前分类、分割平滑和未来标签预测。

```
L = L_cls + L_seg + L_pre
```

6. 推理阶段：从标签序列派生三任务

Imagegen 图：标签序列、平滑与预测 — observed labels -> segments -> forecast



Recognition

每个 patch 的标签就是局部活动识别结果；活动段标签可由相邻 patch 合并后得到。

Segmentation

对 y_hat 使用 smoothing window 做 majority correction，再合并相邻同类 patch 得到边界 B={(s_i,e_i)}。

Forecast

输出未来 8 个 patch 的类别序列，可直接判断接下来活动是否延续或切换。

对方向一的迁移

可扩展为 human label sequence + phone motion label sequence，或组合状态序列。

```
state_t = (human_action_t, phone_motion_t)
future states -> continue_prob, switch_prob, next_state, first_switch_patch
```

7. 实验结果：Recognition / Segmentation / Forecast

Imagegen 图：实验现象概览 — qualitative summary, exact numbers below



Recognition: Acc / F1

DATASET	ACC	F1
PAMAP2	98.71%	98.92%
WISDM	97.51%	97.52%
UNIMIB	81.51%	82.04%

论文表 II：P2LHAP 在作者设置下整体优于选定对比方法；UNIMIB F1 比 leading method 高 3.26%。

Segmentation: Jaccard Index

METHOD	JI
Attn	0.7908
A&D	0.8312
JSR	0.8947
Ours w/o smoothing	0.8445
Ours	0.9294

论文表 III：PAMAP2 上 smoothing 对分割边界非常关键。

Forecast: PAMAP2

SIGNAL FORECASTER	MSE
SynSigGAN	0.355
Conv2LSTM	0.302
Seq2Seq-LSTM	0.240
TTS-GAN	0.163
Ours	0.126

未来 8 个 patch 的活动类别预测平均准确率约 96.59%；表 IV 还比较未来传感器信号预测 MSE。

Complexity: PAMAP2

METHOD	PARAM	TIME
Attn	1.983M	8.22
A&D	1.503M	11.88
JSR	2.799M	0.78
Ours	1.449M	0.08

表 VIII：作者报告更低参数量和推理时间，说明框架有移动/嵌入式潜力。

8. 消融实验：为什么 patch 和结构有效

Patch Size 对 F1 的影响

DATASET	P=1	P=2	P=5	P=10	P=20
WISDM	0.8544	0.9056	0.8819	0.9751	0.9568
PAMAP2	0.9151	0.9406	0.9610	0.9892	0.9667
UNIMIB	0.6719	0.6950	0.7566	0.8204	0.7876

No Patching vs P2LHAP

MODEL	WISDM	PAMAP2	UNIMIB
Transformer only	0.9090	0.8783	0.7533
P2LHAP	0.9752	0.9892	0.8204

Depth / Heads

论文在 PAMAP2 上调节 encoder-decoder 层数和 attention heads。最佳默认配置为 6 层、8 heads；继续加到 16 heads 或 8 层不一定更好。

结论：patch 组织、合适模型容量和 smoothing 都是性能来源，不只是“换成 Transformer”。

9. 局限与对本课题的使用方式

论文局限

- closed-set softmax，不能拒识未知活动。
- 数据划分为连续流 0.7/0.1/0.2，不是跨受试者验证。
- 数据集不是 UCI HAR，也不是手机运镜双标签场景。
- 仍需设置 patch size、stride、forecast horizon。
- channel-independent 减少干扰，但可能弱化真实跨通道耦合。

对方向一的启发

- 把“延续/切换”建模为未来 patch 标签序列预测。
- 从未来序列派生 continue_prob 与 switch_prob。
- 将单标签扩展为双标签：人体动作 + 手机/相机运动。
- 或把二者组合成 joint state sequence。
- 先评估 segmentation/forecast，再讨论语义对齐或多模态。

最重要的迁移点不是直接照搬模型，而是采用 patch-level future label sequence 作为“未来延续概率”和“切换趋势预测”的基础输出。

Paper: P2LHAP: Wearable sensor-based HAR, segmentation and forecast through Patch-to-Label Seq2Seq Transformer | arXiv:2403.08214