方向一方法设想 | Smartphone IMU Activity Forecasting

基于 Future Patch Label Sequence 的动作延续与切换预测

预测当前与未来 patch 的标签序列，再由序列变化和分类置信度推导延续概率、切换时机和下一动作。

组会定位：研究方案草案。已完成范式梳理、模型结构选择、训练策略设计和示意图制作；尚未宣称完成实验。

1. 问题重述

输入：手机 IMU 连续序列

acc x/y/z + gyro x/y/z

输出：当前动作、未来动作序列、延续概率、切换时机、下一动作

past IMU patches -> p(y_t)...p(y_{t+H})

2. 为什么不主用 transition class

- <sit-2-stand> 有直觉价值，但作为主标签会带来类别膨胀与样本稀疏
- 较新的相近任务更常预测未来标签序列或动作段，而非枚举所有 A-to-B 切换。
- 未来序列中第一次 label 变化给出切换时机；变化后的 label 就是下一动作。

transition type 可作为后续辅助头或分析标签。

3. 相关范式依据

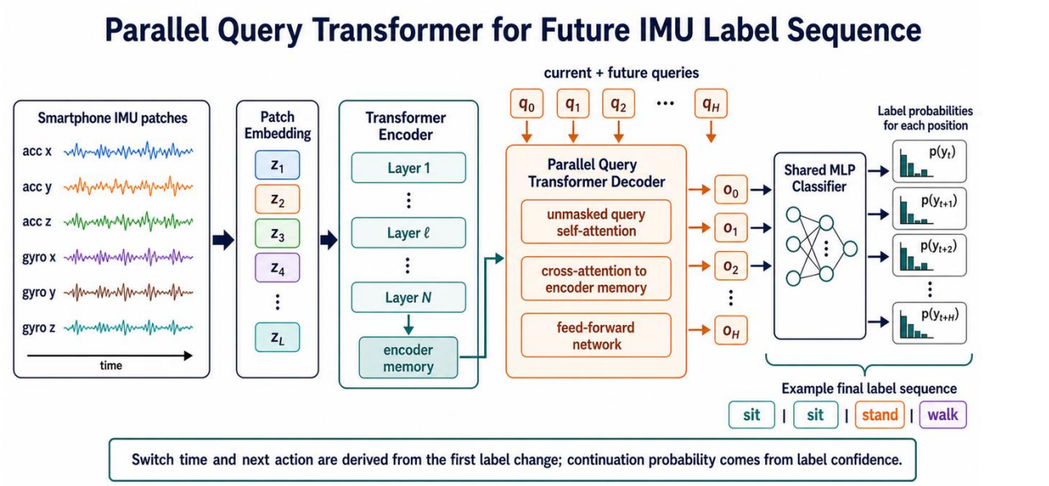
P2LHAP
sensor patches -> patch-level label sequence，forecast 直接输出未来活动标签。

FUTR
learnable action queries 并行预测未来动作与 duration，避免自回归错误累积。

ActFusion
把未来不可见部分视作 mask tokens，通过补全动作序列完成 anticipation。

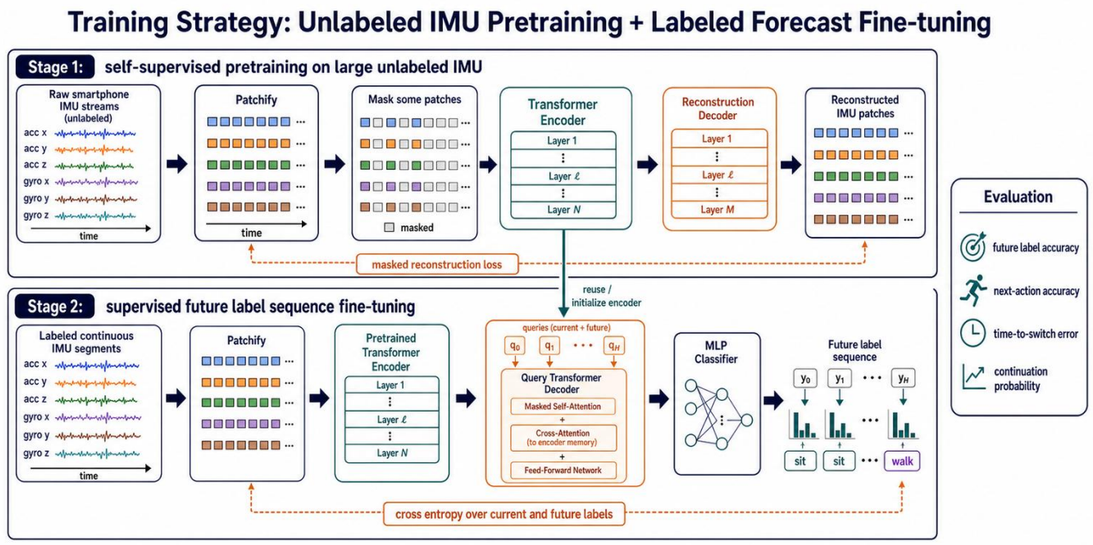
本方法
parallel query decoder 为主；自回归 decoder 作为后续消融。

4. 模型结构：Transformer Encoder + Parallel Query Decoder



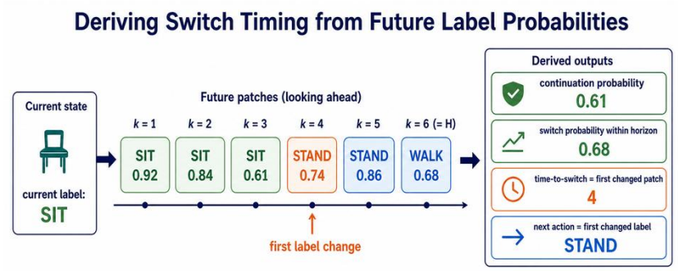
历史 IMU patch tokens 进入 Transformer Encoder；q0...qH 表示当前与未来 horizon queries；decoder 并行输出 o0...oH，并由共享 MLP classifier 得到标签分布。

5. 训练策略：无标签预训练 + 有标签微调



注：Stage 2 的 label prediction 采用 unmasked parallel query decoder；mask 只用于 Stage 1 的 masked IMU reconstruction 预训练。

6. 如何推导切换输出



time_to_switch = first changed patch
next_action = first changed label

7. 损失函数与样本构造

从连续流中取过去 L 个 patch 作为输入，未来 H 个 patch label 作为 target。

input = X[t-L+1 : t]
target = y[t : t+H]

L = CE(y_t) + lambda * sum CE(y_{t+k})
k = 1...H；远期 horizon 可降权

8. 后续实验计划

数据 连续 HAR 数据验证 future label sequence；UCI HAR 只做 encoder sanity check。

结构 early fusion、P2LHAP-style channel independent、hybrid cross-channel fusion。

训练 from scratch、masked reconstruction pretraining、future IMU regression。

评价 future accuracy、next-action accuracy、time-to-switch error、calibration。

方向一扩展：从 single human label sequence 升级到 human_action_sequence + phone_motion_sequence。

Figures: imagegen | Poster/PPT: local generation