面向手机视频的移动端行为识别研究

基于手机IMU的人体行为与运镜行为联合建模、识别和预测

行为识别的范围

人体行为（示例）

站立　坐　走路　跑步　上楼　下楼　切换动作

不局限于以上人体行为，包含更多日常行为及其切换动作

运镜行为（示例）

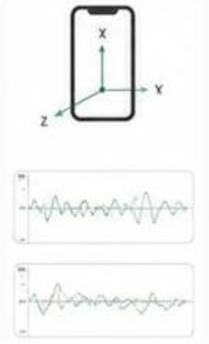
静持　推　拉　摇　移　切换动作

不局限于以上运镜行为，包含更多日常行为及其切换动作

任务描述

IMU输入

加速度计+陀螺仪



联合行为建模

- 时序特征融合
- 行为组合理解
- 切换状态建模

行为状态预测

- 当前行为类别
- 未来延续概率
- 切换趋势预测

输出与应用

高精度识别
区分人体行为、运镜行为及典型切换状态

行为趋势预测
预测当前行为是否会继续延续及切换时机

实时轻量部署
满足移动端资源约束

研究挑战

数据集构建
各类行为的定义与标注

行为组合复杂
人体行为与运镜行为自由组合，需分别准确识别

泛化性
不同人、不同习惯、不同场景差异大

实时性与轻量化
移动端算力受限

部署场景

视频-缓存模式

- 未来缓存IMU信息可用
- 追求更高的行为识别精度

视频-实时模式

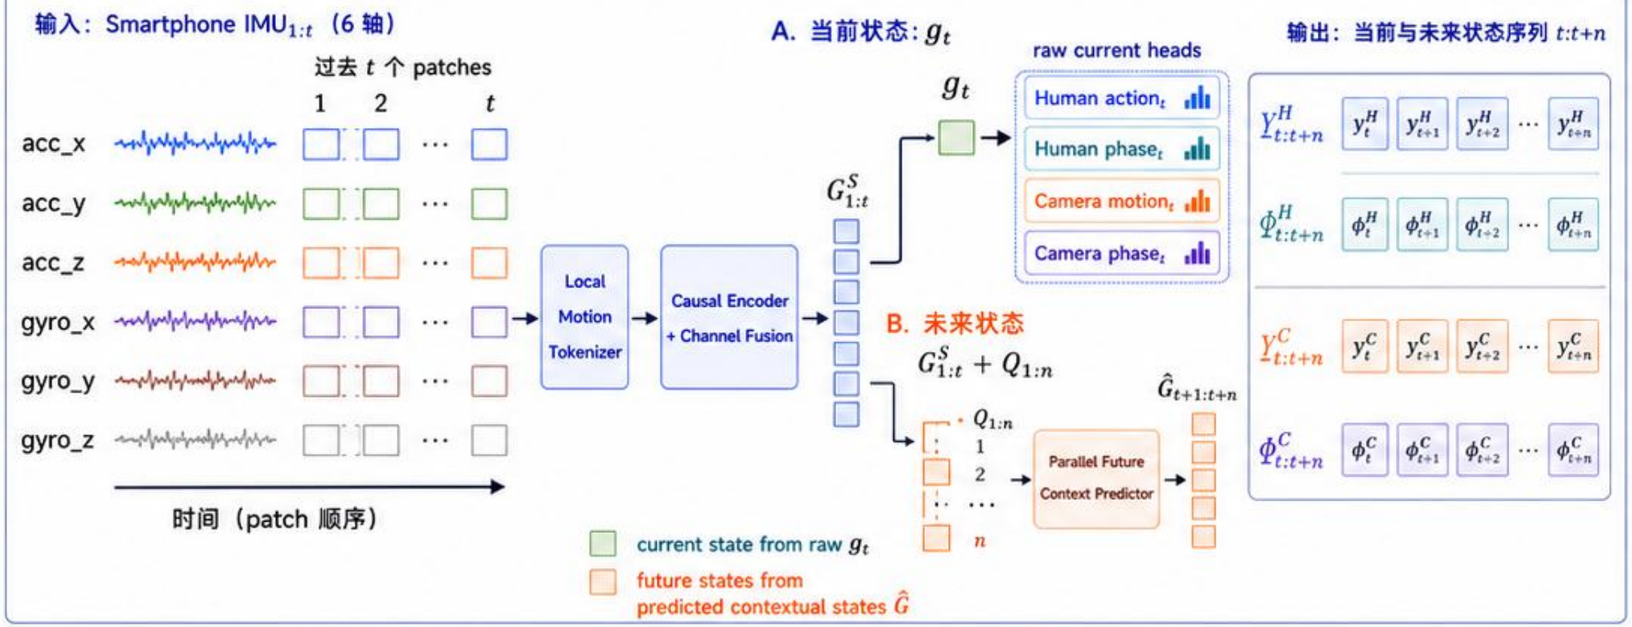
- 仅当前帧及历史帧IMU信息
- 实时推理，输出行为类别+未来变化概率

关键技术方向

- 多模态时序特征建模
- 组合行为识别
- 行为状态变化预测
- 模型轻量化与实时性优化

目标任务

数据流与预测目标



双流状态定义

人体动作流 Y^H

standing	walking	sitting	turning	body_static	hand_movement

相机运动流 Y^C

static	pan	tilt	roll	shake	reposition

人体阶段流 Φ^H

stable（稳定延续） | transition（人体状态切换过程）

相机阶段流 Φ^C

stable（稳定延续） | transition（相机状态切换过程）

Camera motion = dominant-motion single-label.

为什么不能只做当前分类

- 当前窗口分类只能回答“现在是什么”
- 未来 horizon 才能描述延续趋势
- 序列输出可读取切换时机与下一状态

Current-only（窗口级）

$IMU_{1:t}$ → g_t → 当前标签

Future sequence prediction（窗口级）

$G^S_{1:t} + Q_{1:n}$ → $\hat{G}_{t+1:t+n}$ → 未来 n 个标签

current / future use same four heads

示例：双流预测输出与切换时机

	t−2	t−1	t	t+1	t+2	t+3	t+4	t+5
人体动作 Y^H	stand	stand	stand	stand	stand	walk	walk	walk
人体阶段 Φ^H	stable	stable	stable	stable	stable	transition	stable	stable
相机运动 Y^C	static	static	static	pan	pan	pan	pan	pan
相机阶段 Φ^C	stable	stable	stable	transition	stable	stable	stable	stable

Camera $\tau_C = 1$　　Human $\tau_H = 3$

$$\tau = \min\{k \geq 1 \mid \hat{Y}_{t+k} \neq \hat{Y}_t\}$$

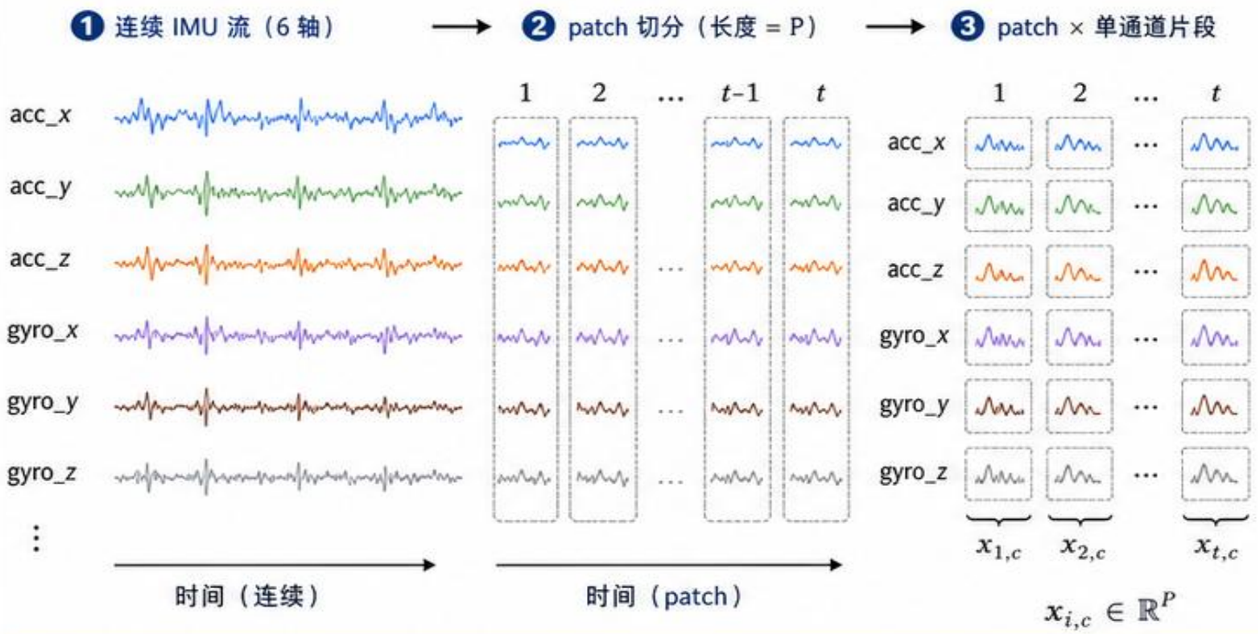
$$T_{switch} = \tau \times T_{patch}$$

T^H_{switch} = 3 × patch duration

T^C_{switch} = 1 × patch duration

数据形式

输入序列



$X_{1:t} \in \mathbb{R}^{L \times P \times C}$	$x_{i,c} \in \mathbb{R}^P$	$C = 6$ channels
$L = t$（patch 数）	第 i 个 patch，第 c 个通道	acc_x, acc_y, acc_z, gyro_x, gyro_y, gyro_z

Patch duration = Δt

标签序列

时间（patch 序号）	t（当前）	$t+1$	$t+2$	…	$t+n$
人体动作（Y^H）	stand	stand	stand	walk	walk
人体阶段（Φ^H）	stable	stable	transition	transition	stable
相机运动（Y^C）	static	static	pan	pan	pan
相机阶段（Φ^C）	stable	transition	transition	stable	stable

推理输出

输出项	读取方式
当前状态	time t 的 action / phase
延续趋势	future labels 是否保持不变
切换时机	smoothed sequence 中第一次变化
下一状态	第一次变化后的 label

关键要求　标签必须按**连续时间对齐**；　human 与 camera 两条流**分别标注**，　phase 只包含 stable / transition。

整体方法框架

Student 主路径

Raw IMU$_{1:t}$
(acc_x, acc_y, acc_z, $gyro_x$, $gyro_y$, $gyro_z$)

acc_x
acc_y
acc_z
gyro_x
gyro_y
gyro_z

→ **Single-channel patches**
（按通道切成 patches）

时间 →

→ **Local Motion Tokens** $Z_{1:t}$

形状：$[C,\ t,\ D]$

→ **Channel-independent Causal Encoder**
（因果编码）

形状：$[C,\ t,\ D]$

→ **Same-time Channel Fusion**
（通道融合）

形状：$[t,\ D_f]$

→ $G^S_{1:t}$

A. 当前预测（由 g_t）

g_t →
- Human action$_t$ (Y^H_t)
- Human phase$_t$ (Φ^H_t)
- Camera motion$_t$ (Y^C_t)
- Camera phase$_t$ (Φ^C_t)

B. 未来预测（由 $G^S_{1:t} + Q_{1:n}$）

$G^S_{1:t}$ + Future Queries $Q_{1:n}$ → **Parallel Future Context Predictor**
（并行未来预测器）→ $\hat{G}_{t+1:t+n}$ →
- $Y^H_{t+1:t+n}$
- $\Phi^H_{t+1:t+n}$
- $Y^C_{t+1:t+n}$
- $\Phi^C_{t+1:t+n}$

EMA Teacher（无标签预训练）

Raw IMU$_{1:t+n}$
(acc_x, acc_y, acc_z, $gyro_x$, $gyro_y$, $gyro_z$)

acc_x
acc_y
acc_z
gyro_x
gyro_y
gyro_z

→ **EMA Teacher Backbone**
（与 Student 结构相同）

→ $G^T_{1:t+n}$

形状：$[t+n,\ D_f]$

→ **最终融合目标** $G^T_{t+1:t+n}$

形状：$[n,\ D_f]$

→ **Parameter-free LayerNorm**
（无仿射）

$LN_{no_affine}(\cdot)$

→ **Stop-gradient Targets**
（$sg(\ldots)$）

形状：$[n,\ D_f]$

$$\mathcal{L}_{future} = \sum_{k=1}^{n}\left[1 - \cos\left(\hat{g}_{t+k},\ sg\left(LN_{no_affine}\left(g^T_{t+k}\right)\right)\right)\right]$$

cos：余弦相似度　sg: stop-gradient　LN_{no_affine}：无仿射 LayerNorm

训练 / 微调协议

Pretrain（无标签预训练）

仅最小化 $\mathcal{L}_{future}$：

$$L = \mathcal{L}_{future}$$

输出使用
- 仅使用未来分支的预测结果 $\hat{G}_{t+1:t+n}$
- 与 EMA Teacher 目标对齐，无需标签

Finetune（有标签微调）

仅最小化 $\mathcal{L}_{sup}$：

$$L = \mathcal{L}_{sup}$$

输出使用
- 使用当前分支与未来分支的四类预测头
- 监督信号：对应标签（Y，Φ）

Inference（推理）

- 原始输出（时间 t）：直接使用当前分支预测结果
- 趋势与切换时机：对输出序列平滑后，再读取趋势与切换时刻

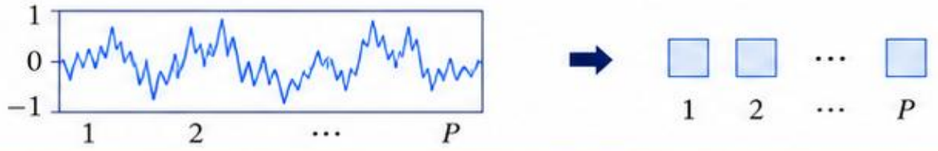
Local Motion Token 构造

单通道局部运动单元

1 原始波形片段

第 i 个 patch / 第 c 个通道

$$x_{i,c} \in \mathbb{R}^P$$

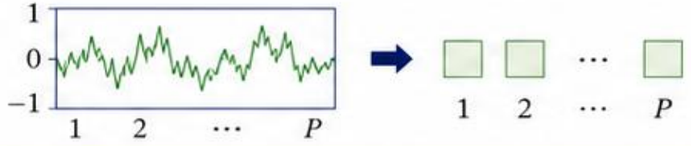


2 实例归一化

去除通道内幅值差异

$$\mu_{i,c} = Mean(x_{i,c}), \quad \sigma_{i,c} = Std(x_{i,c})$$

$$x_{i,c}^{norm} = \frac{x_{i,c} - \mu_{i,c}}{\sigma_{i,c} + \varepsilon}$$



3 轻量级 1D CNN 局部运动编码器

$x_{i,c}^{norm}$ → f_{motion} → $u_{i,c} \in \mathbb{R}^{D_u}$



4 元信息与统计量

显式保留通道身份与统计信息

$[\mu_{i,c},\ \sigma_{i,c}]$ + m_c = [sensor one-hot; axis one-hot]

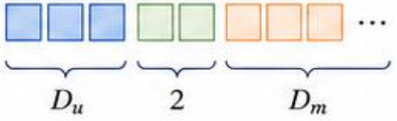
示例：acc_x = [1, 0, 1, 0, 0]

gyro_z = [0, 1, 0, 0, 1]



5 拼接并投影 + 时间位置编码

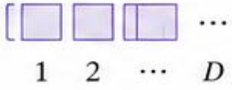
$[u_{i,c};\ \mu_{i,c};\ \sigma_{i,c};\ m_c]$



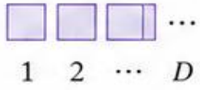
Fusion Projection

$W_f \in \mathbb{R}^{D\times(D_u+2+D_m)}$

$h_{i,c} \in \mathbb{R}^D$



$z_{i,c} \in \mathbb{R}^D$



时间位置编码 $p_i \in \mathbb{R}^D$ → ⊕

核心公式

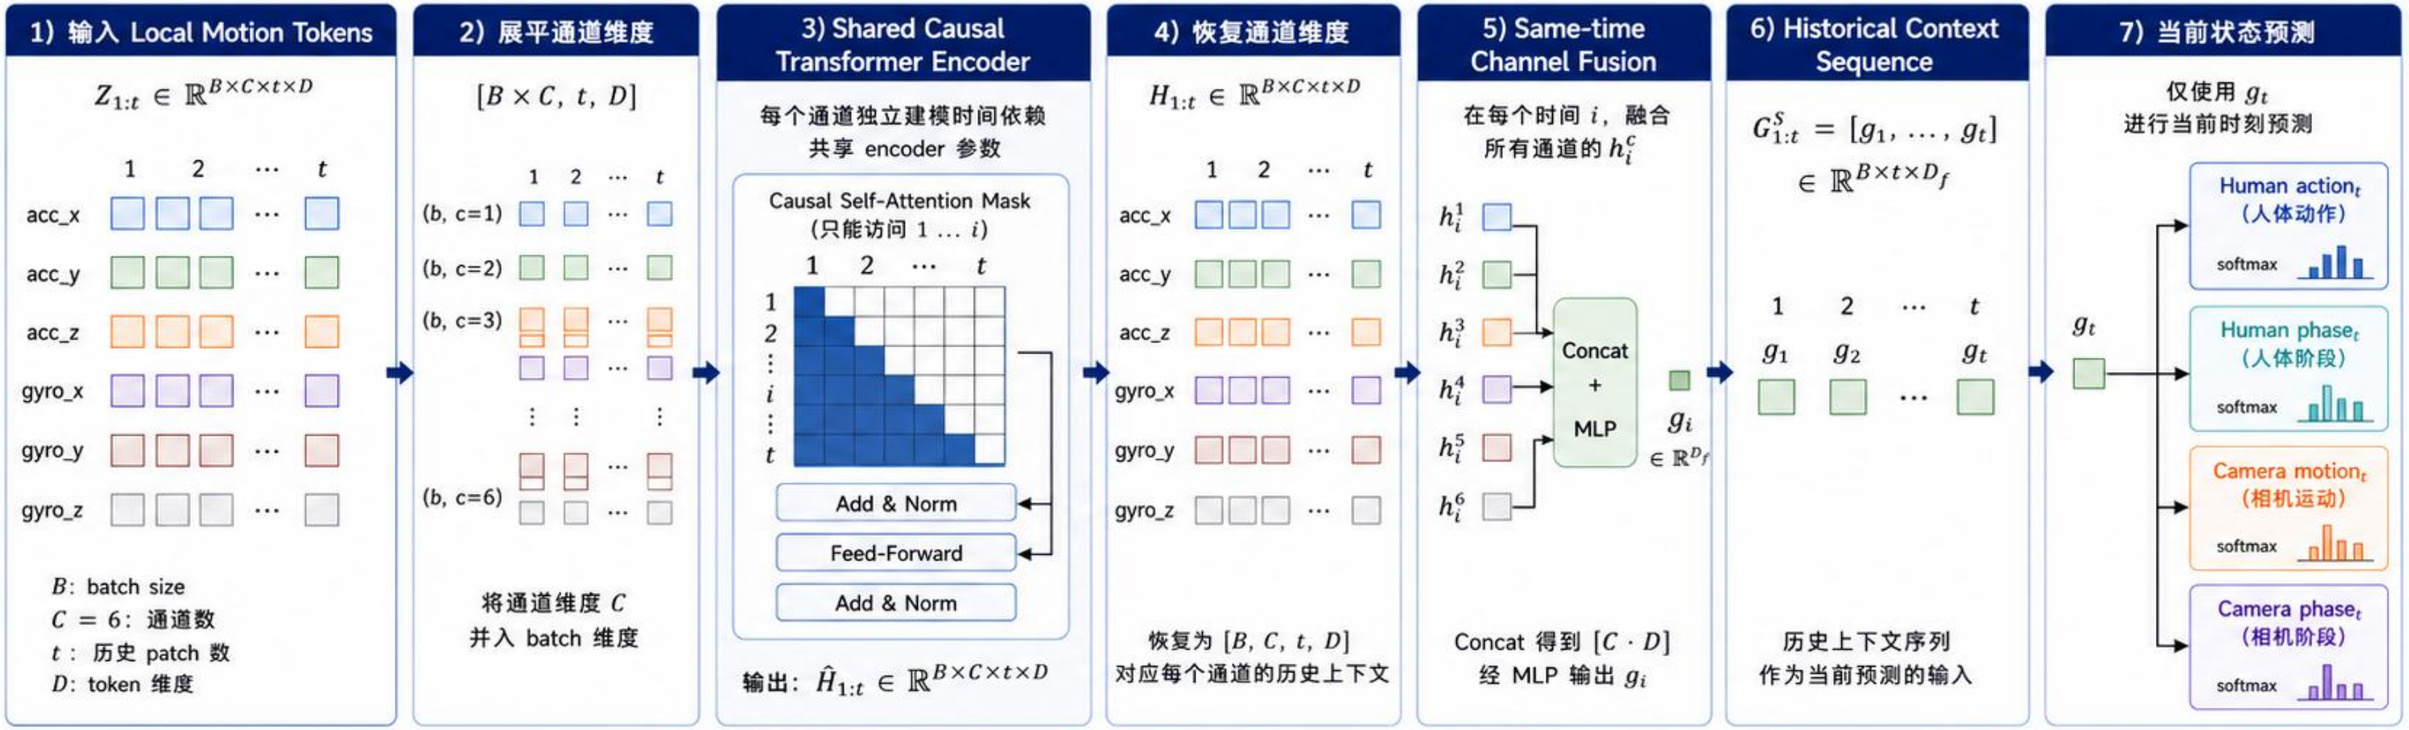
$$z_{i,c} = f_{fuse}\left(\left[f_{motion}(x_{i,c}^{norm});\ \mu_{i,c};\ \sigma_{i,c};\ m_c\right]\right) + p_i$$

Component	Meaning
$u_{i,c}$	归一化局部波形表示
μ, σ	幅值偏移与波动强度
m_c	sensor type + axis identity
p_i	patch temporal position

设计要点

- 局部波形主体由 1D CNN 学习
- 统计量保留 normalization 去除的幅值信息
- 通道身份显式区分 acc / gyro 与 x-y-z

当前状态预测



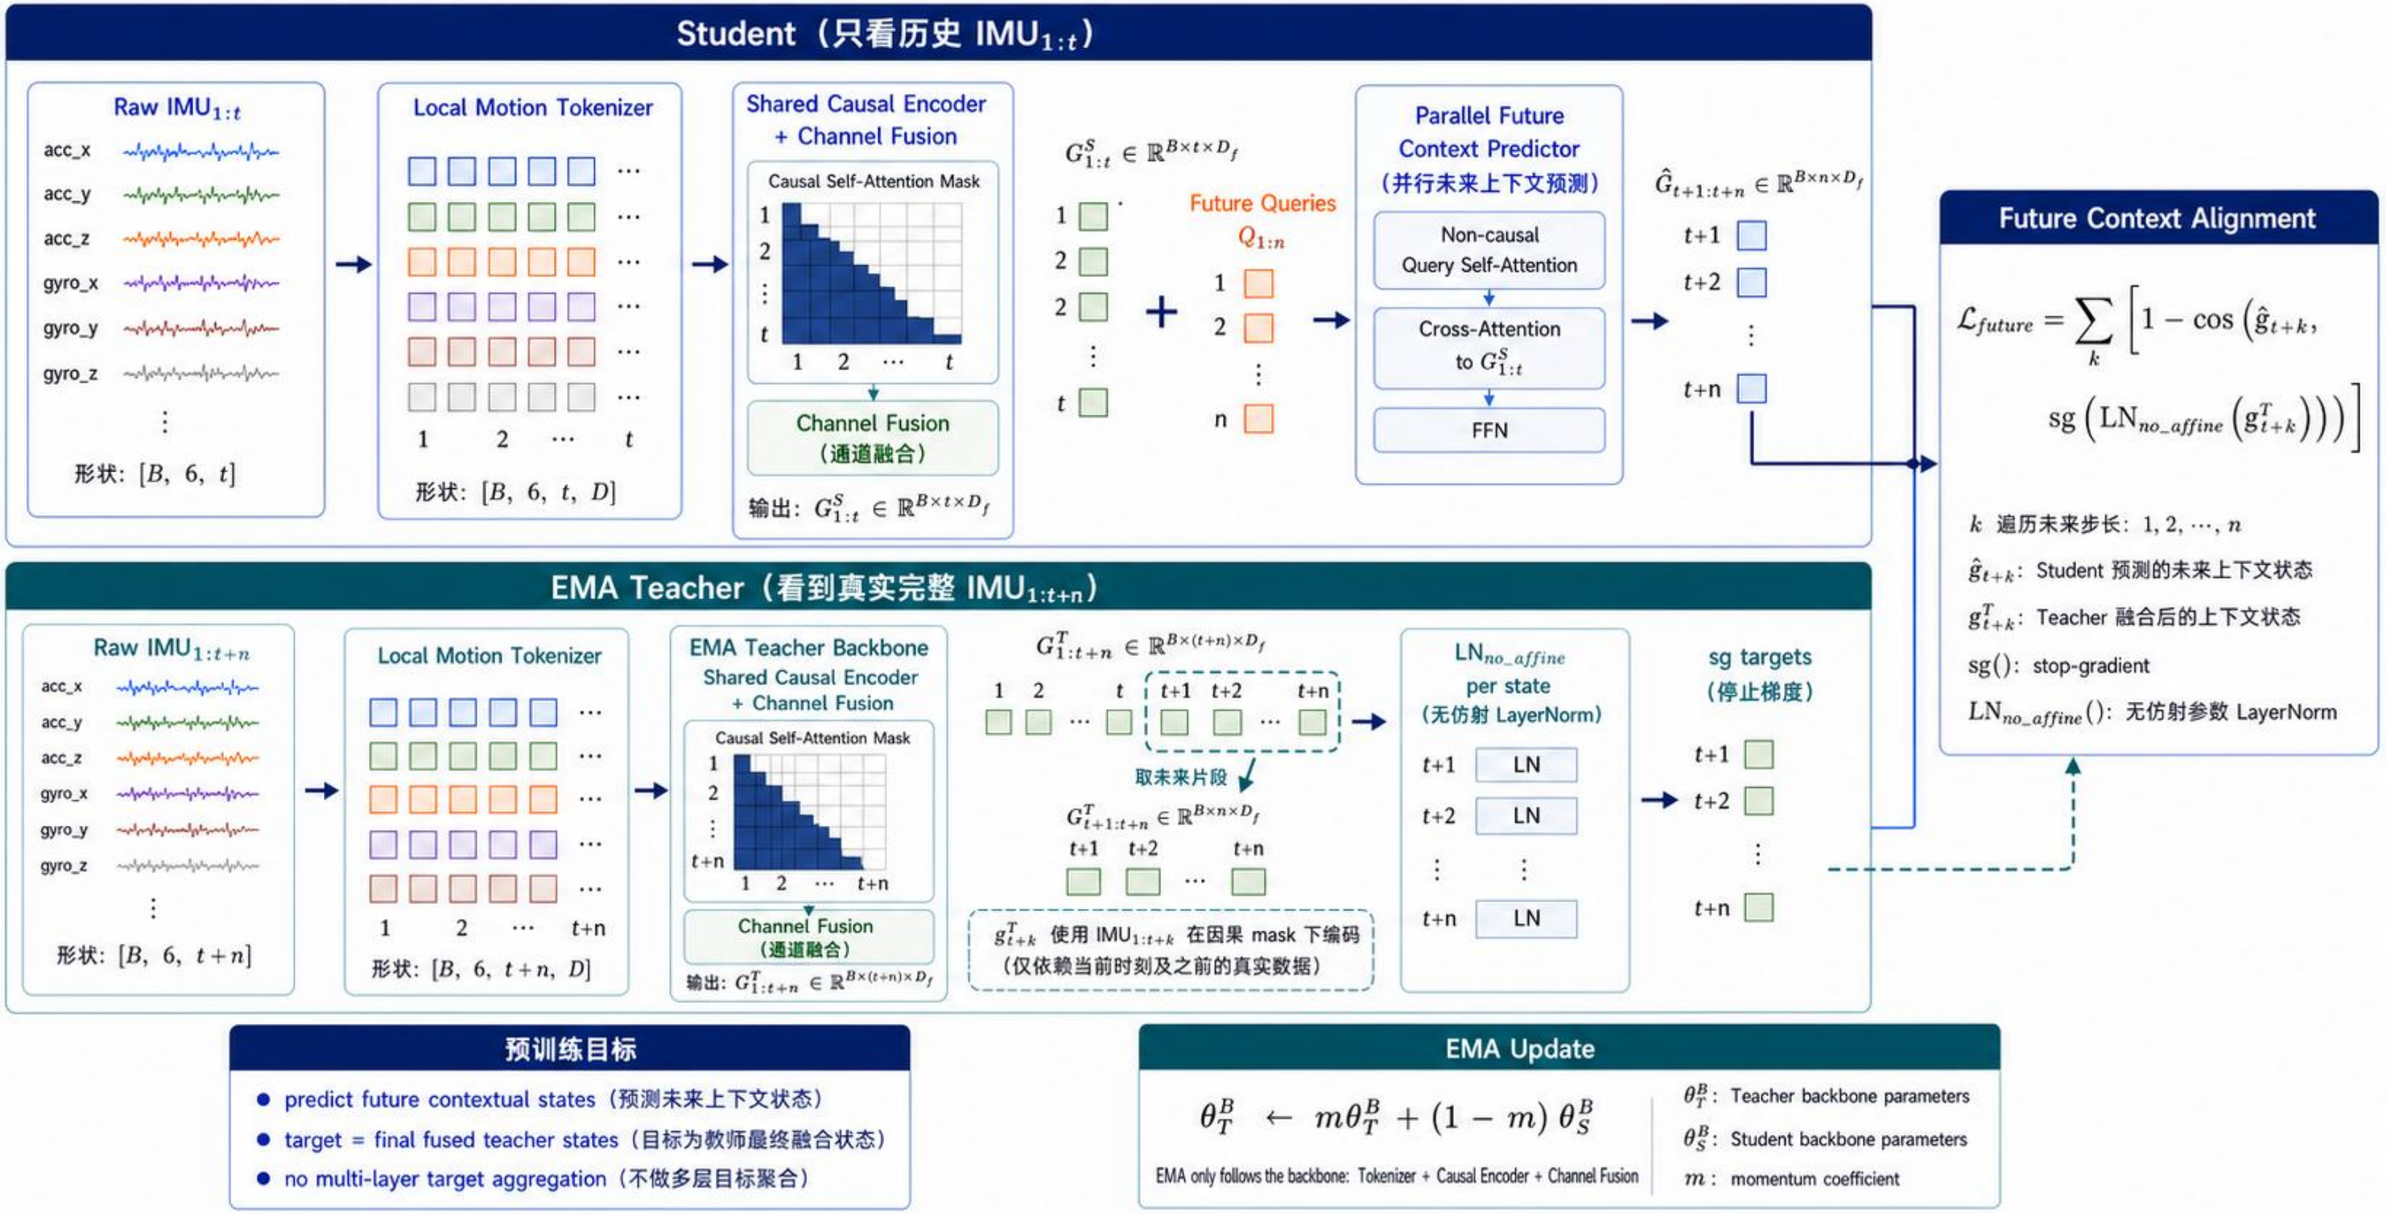
结构约束

- attention complexity $\approx O(C \cdot t^2)$：
  由于每个通道独立做 causal attention，整体复杂度约为 C 倍的 t^2。
- sensor / axis 信息在 token 中显式保留：
  不在此阶段丢失通道身份与物理含义。
- 当前识别使用 raw head output at t：
  不依赖平滑，减少延迟，保证实时性。

表示含义

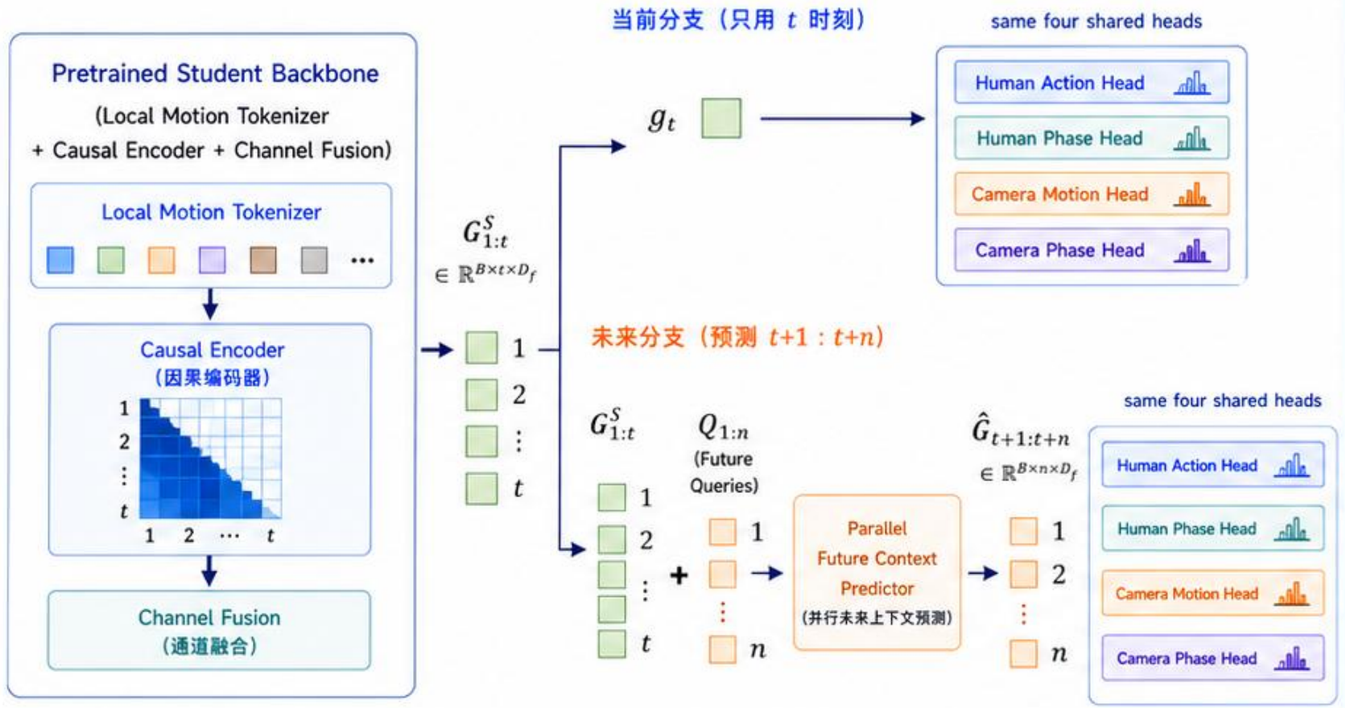
- h_i^c：单通道历史上下文
  表示通道 c 在时间 i 的历史信息编码（仅依赖 1 … i）。
- g_i：同一时间的六轴融合上下文状态
  融合所有通道在时间 i 的信息，得到统一的语义上下文表示。
- g_t：当前时刻语义预测入口
  直接作为当前时刻多任务预测的输入，输出各类当前状态。

无标签预训练：EMA Future Context Distillation



有监督微调与推理读数

有监督微调



Loss（在 $t{:}t{+}n$ 上计算）

$$\mathcal{L}_{sup} = CE_{H_action} + CE_{H_phase} + CE_{C_motion} + CE_{C_phase}$$

- Pretrain: $\mathcal{L}_{future}$ only
- Finetune: $\mathcal{L}_{sup}$ only
- EMA Teacher discarded after pretraining

输出序列

	t	$t{+}1$	$t{+}2$	…	$t{+}n$
$Y^H_{t:t+n}$ (human action labels)	stand	stand	stand	…	walk
$\Phi^H_{t:t+n}$ (stable / transition)	stable	stable	stable	…	stable
$Y^C_{t:t+n}$ (camera motion labels)	static	pan	pan	…	tilt
$\Phi^C_{t:t+n}$ (stable / transition)	stable	transition	transition	…	stable

推理读数

1）当前识别（当前状态）

g_t (current) → raw head output at t → 当前状态（当前时刻识别）

2）趋势读数（切换时机）

预测标签序列 $Y_{t:t+n}$ → $\hat{Y}_t$ $\hat{Y}_{t+1}$ $\hat{Y}_{t+2}$ … $\hat{Y}_{t+n}$ → local smoothing → 第一个与 Y_t 不同的 label（新 label） → 切换时刻（时间 / 秒）

$$\tau = \min\{k \geq 1 \mid \hat{Y}_{t+k} \neq \hat{Y}_t\}$$

$$T_{switch} = \tau \times T_{patch}$$

示例（human action）

t	$t{+}1$	$t{+}2$	$t{+}3$	$t{+}4$
stand	stand	stand	walk	walk

第一个新 label 出现位置（$\tau = 3$）

$$\tau = 3$$

$$T_{switch} = 3 \times T_{patch}$$

28 Oct 2025

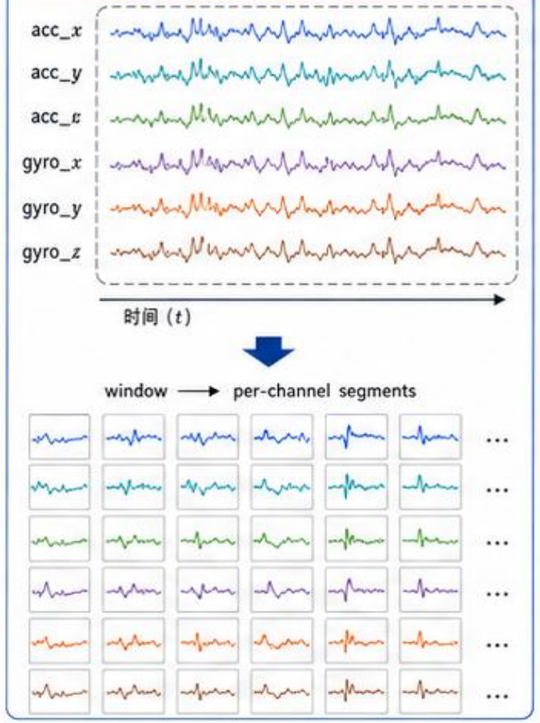
MoPFormer: Motion-Primitive Transformer for Wearable-Sensor HAR

Hao Zhang[1]*, Zhan Zhuang[1,2]*, Xuehao Wang[3], Xiaodong Yang[4], Yu Zhang[1]†

为什么需要 motion primitive

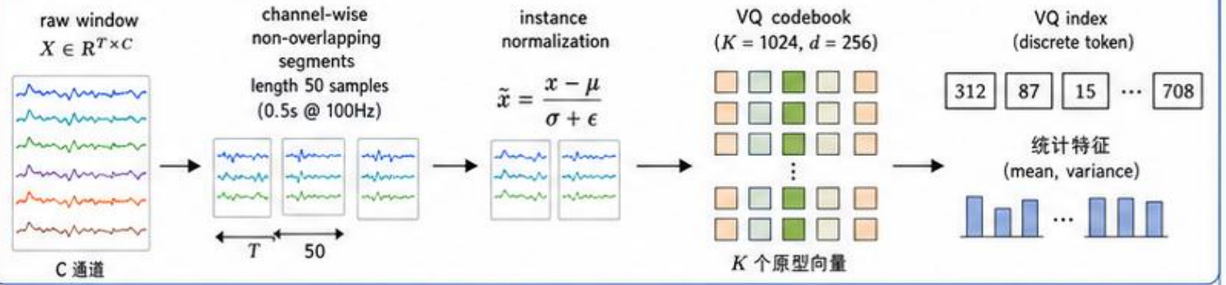
- IMU 是连续数值序列，直接解释困难
- 不同数据集的传感器位置、通道与采样设置差异明显
- 许多活动由更基础的局部运动模式组合而成

输入：多通道 IMU window

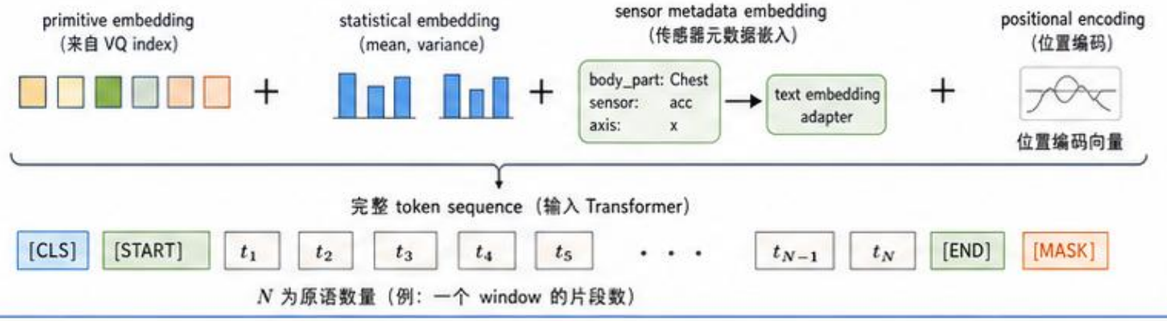


模型与数据管线

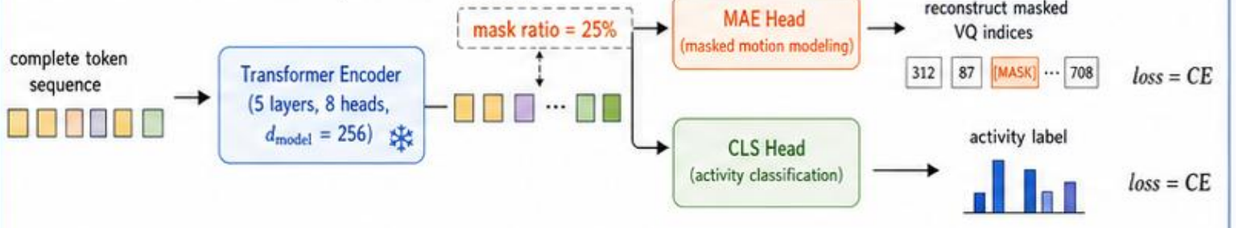
A. Motion Primitive Module （动作原语模块）



B. Context-Aware Embedding Module （上下文感知嵌入模块）

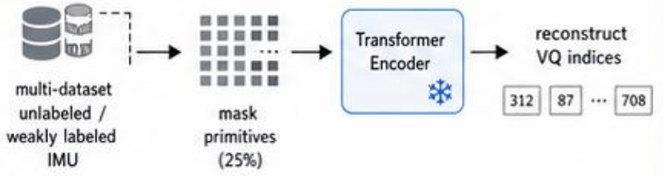


C. Transformer + Task Heads （Transformer 与任务头）

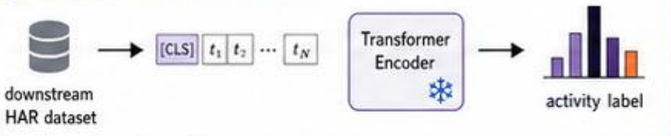


训练策略

Stage 1 Pretraining （预训练）



Stage 2 Fine-tuning （微调）



备注：原语分词器 / primitive vocabulary 提升可解释性并增强跨数据集迁移能力。

实验数据集

PAMAP2	DSADS	MHealth	Realworld	UCI-HAR	USC-HAD
9 类	19 类	12 类	13 类	6 类	12 类

主要结果（平均值）

Method	Avg Acc (↑)	Avg F1 (↑)
BYOL+Mixup	86.00	84.72
ModCL	86.88	85.98
TSLANet	89.28	88.13
CALANet	87.16	85.70
MoPFormer	90.17	89.23
w/o Pretrain	86.45	85.25

learned primitives show activity-specific frequency patterns, improving interpretability.

冻结参数（预训练阶段） 可训练参数（微调阶段） 离散原语 token 特殊 token 统计特征 元数据嵌入 数据流向 表示监督信号流向

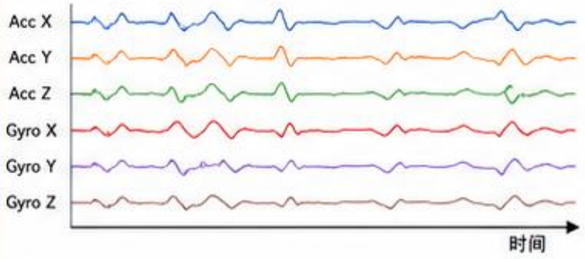
Sep 2024

P2LHAP: Patch-to-Label Seq2Seq Transformer

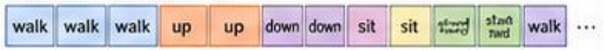
Shuangjian Li, Tao Zhu, *Member, IEEE*, Mingxing Nie, Huansheng Ning, *Senior Member, IEEE*, Zhenyu Liu and Liming Chen *Senior Member, IEEE*

任务形式

连续多通道可穿戴传感器序列（示例：6 通道）



Patch-level label sequence



HAR 每个 patch 的活动类别

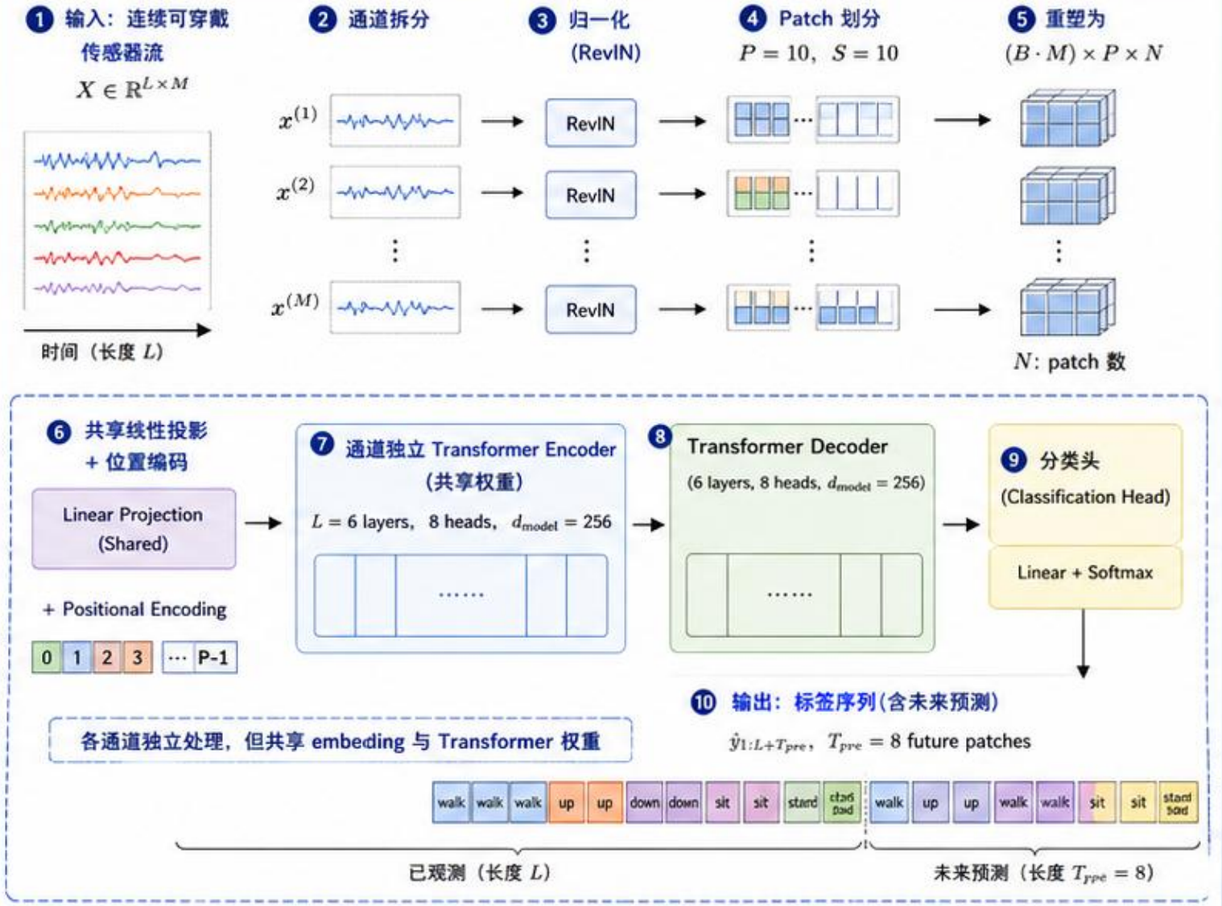
HAS 相邻同类 patch 合并得到活动段边界

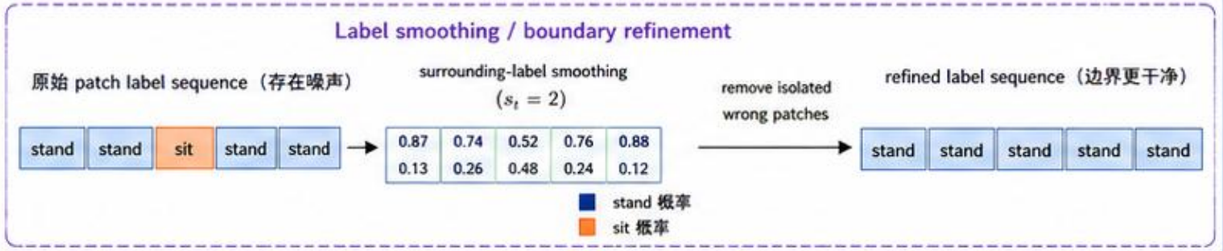
HAF 继续输出未来 n 个 patch 的标签

为什么用 Patch-to-Label

- ☑ **避开固定滑动窗口长度难题**
  以固定长度 patch 表示片段，天然适配活动长短不一。
- ☑ **短暂过渡动作可被 patch 捕捉**
  过渡动作往往持续时间短，patch 级表示更易捕获边界变化。
- ☑ **输出天然是label sequence，便于分割与预测**
  模型直接输出按时间排列的标签序列，方便边界提取与未来活动预测。

模型与数据管线





实验设置与指标

数据集统计

Datasets	WISDM	PAMAP2	UNIMIB SHAR
Channels（通道数）	3	9	3
Activities（活动类别数）	6	12	17

评价指标

Recognition（识别）	Accuracy, Weighted F1
Segmentation（分割）	Jaccard Index (Intersection over Union)
Forecast（预测）	future label accuracy / MSE

主要结果

表1 Recognition（加权 F1，%）

Method	WISDM	PAMAP2	UNIMIB SHAR
P2LHAP (Ours)	97.52	98.92	82.04

表2 Segmentation on PAMAP2 (Jaccard Index↑)

Method	A&D	JSR	Ours
P2LHAP (Ours)	0.8312	0.8947	0.9294

表3 Forecast（MSE ↓）on PAMAP2

Method	Seq2Seq-LSTM	TTS-GAN	Ours
P2LHAP (Ours)	0.240	0.163	0.126

可借鉴点

- 用序列标签而不是单窗口标签组织任务，统一处理识别、分割与预测。
- transition / future activity 可从 label sequence 中自然读出，边界与趋势更可解释
- 通道独立 Transformer + 共享权重，在多传感器序列上更稳健，泛化更好。

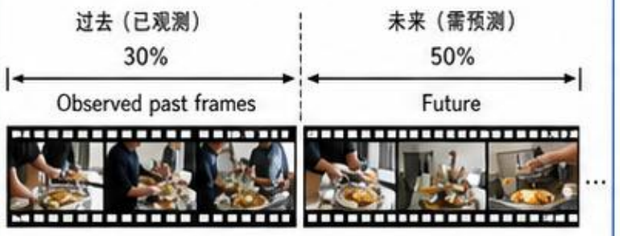
FUTR: Future Transformer for Long-Term Action Anticipation

Dayoung Gong[1] Joonseok Lee[1] Manjin Kim[1] Seong Jong Ha[2] Minsu Cho[1]

任务定义与输入输出

① 任务形式

视频时间线（示例）



动作段（ground truth action sequence）



- 给定观察到的视频片段，预测未来较长时间内 action sequence。
- 输出不是单个标签，而是 segment-level sequence：

  (a_i, d_i)： *future action label* + *normalized duration*

  可加入 NONE class 表示后续 query 无动作。

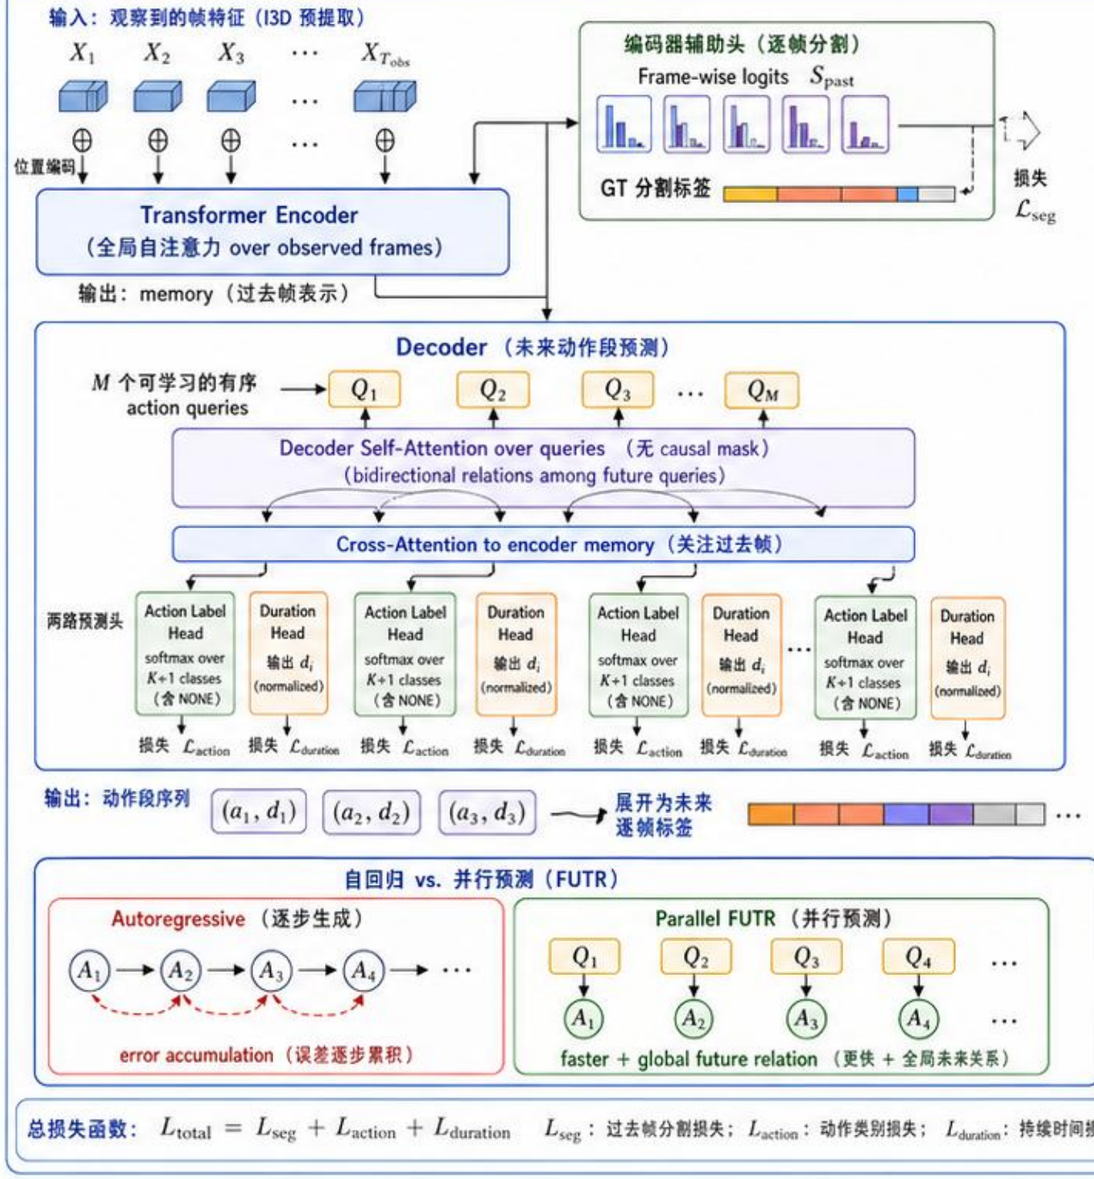
② 为什么不是自回归

RNN / autoregressive decoder 逐步生成，前一步错误会传到后面，误差累计放大。

长期预测需要建模 past frames 与 future actions 的全局关系。

并行输出可以充分利用未来 query 间信息，同时显著降低推理时间。

模型结构与数据流



总损失函数：$L_{total} = L_{seg} + L_{action} + L_{duration}$　L_{seg}：过去帧分割损失；L_{action}：动作类别损失；$L_{duration}$：持续时间损失

实验结论与可借鉴点

A 实验设置

Datasets	Characteristics
Breakfast	1712 videos, 48 fine-grained actions, ~6 actions / video
50 Salads	50 videos, 17 fine-grained actions, ~20 actions / video

Metrics: MoC accuracy under observation α and prediction β。

B 关键实验结果

表1 Breakfast, $\alpha = 0.3$ （MoC accuracy ↑）

Method	$\beta = 0.1$	$\beta = 0.2$	$\beta = 0.3$	$\beta = 0.5$	Time / clip
FUTR-A autoregressive	27.10	25.41	23.28	20.51	14.68 ms
FUTR-M masked queries	31.82	28.55	26.57	24.17	5.70 ms
FUTR parallel (Ours)	32.27	29.88	27.49	25.87	3.91 ms

表2 Output structuring, $\alpha = 0.3$ （MoC accuracy ↑）

Method	$\beta = 0.1$	$\beta = 0.2$	$\beta = 0.3$	$\beta = 0.5$
FUTR-S start-end	29.15	25.51	24.20	21.43
FUTR-H Hungarian	25.26	23.85	22.63	21.45
FUTR sequential duration (Ours)	32.27	29.88	27.49	25.87

C 可借鉴点

- fixed ordered queries 适合预测固定长度未来序列。
- label + duration 比 start-end windows 更稳定，边界更精确。
- 不加 causal mask 的 query decoder 可利用未来 query 间的双向关系，提升长期预测效果。
- 对 IMU 任务可迁移为 future patch label / transition tendency prediction。