大连理工大学
DALIAN UNIVERSITY OF TECHNOLOGY

你的汇报题目

姓名

标题

- 分小标题、分条阐述具体内容
- 为使在场听众在投影上能看清楚、听明白，提出以下建议：
  - 文字大小**不要低于24号**，行间距适中，想突出的重点可用不同颜色或其他方式
  - 图的分辨率不要太低
  - 避免堆砌满屏文字
  - 表述不要“自嗨”，需让他人听明白，结构上尽可能由浅入深、由总至分

背景与动机

透明物体深度估计的特殊困难

透明物体深度估计的特殊困难

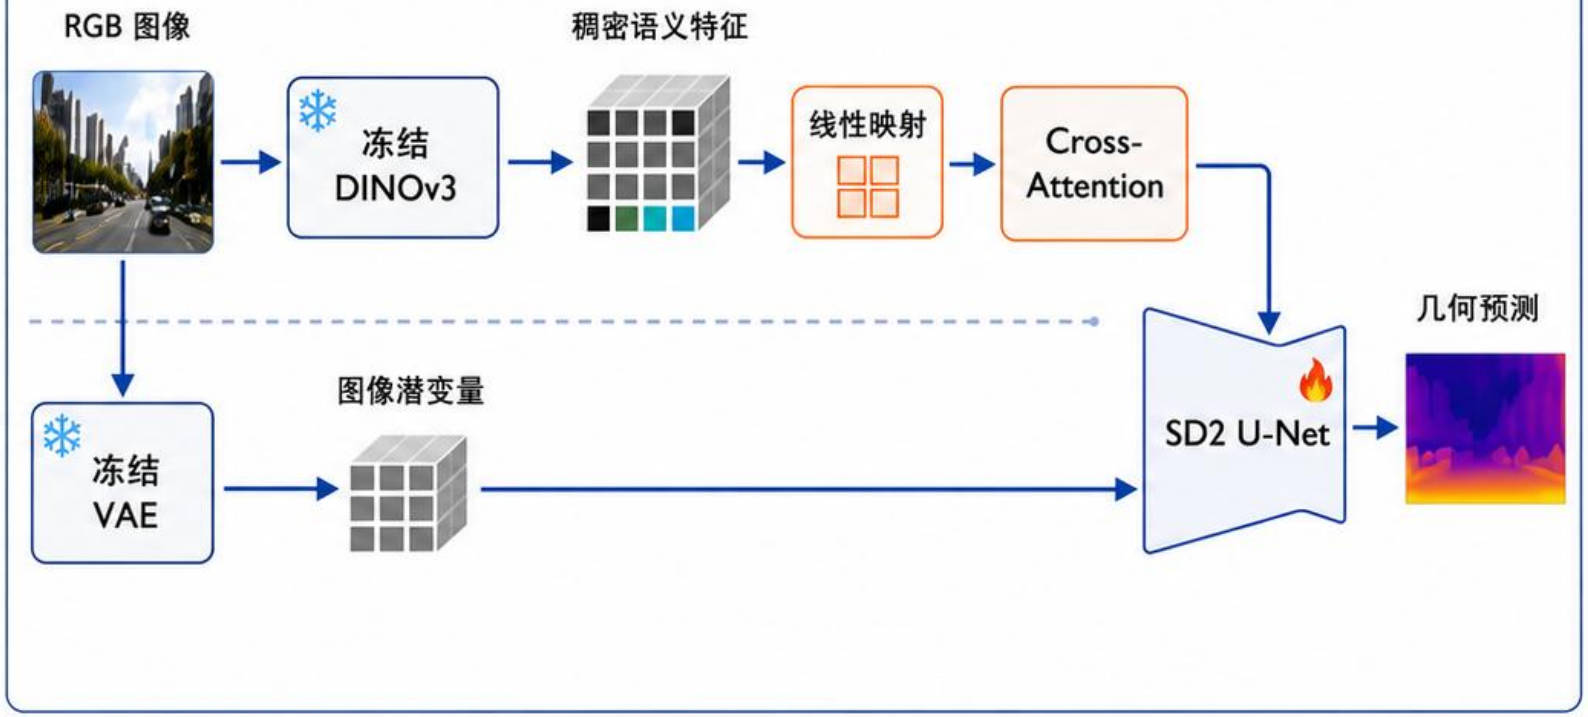
弱纹理与边界模糊：
RGB 外观缺少稳定局部纹理

折射与反射导致形变：
背景和光照被透明介质重写

真实环境复杂干扰：
遮挡、材质与光照变化影响泛化



代表性思路：将 DINO 稠密语义特征注入扩散模型



背景与动机

DINO 特征映射层的改进动机

1 原始做法

DINOv3 输出 patch-level 稠密语义特征，通过线性投影层将其映射到 U-Net 的 **cross-attention 条件通道**，实现维度对齐。

2 存在问题

线性层简单高效，但不显式约束高维语义特征中的**局部近邻结构与相对关系**；映射后可能出现**语义结构变化**，削弱对边界、透明区域及上下文几何关系的表达能力。

3 研究问题

如果投影层造成特征结构扭曲，是否可以通过更具**结构保持能力**的映射方式，**增强语义条件**对透明区域与边界的引导效果？

A 映射前特征

对应原图

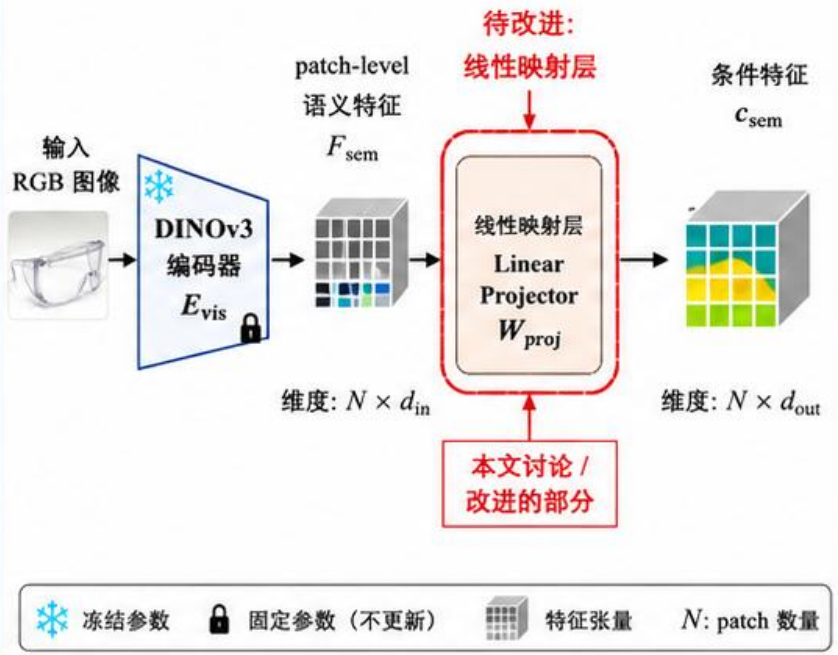


降维前 DINO 特征（PCA 可视化）



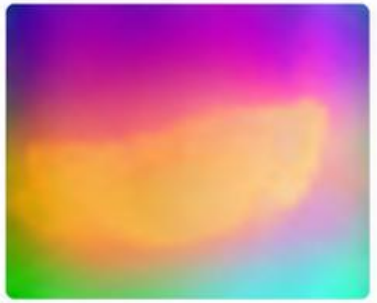
语义区域连贯，结构关系较清晰

B 模型中的对应位置



C 映射后特征

降维后特征（PCA 可视化）



局部结构发生变化，语义边界变得模糊

线性映射虽可完成维度对齐，但**不能显式约束结构保持**。

因此，本文将改进重点聚焦在 **DINO→U-Net 的投影层**，并尝试引入具有结构保持能力的 **RAE** 作为替代映射方式。

本文工作

深度估计任务迁移与基线构建

① 输出任务替换

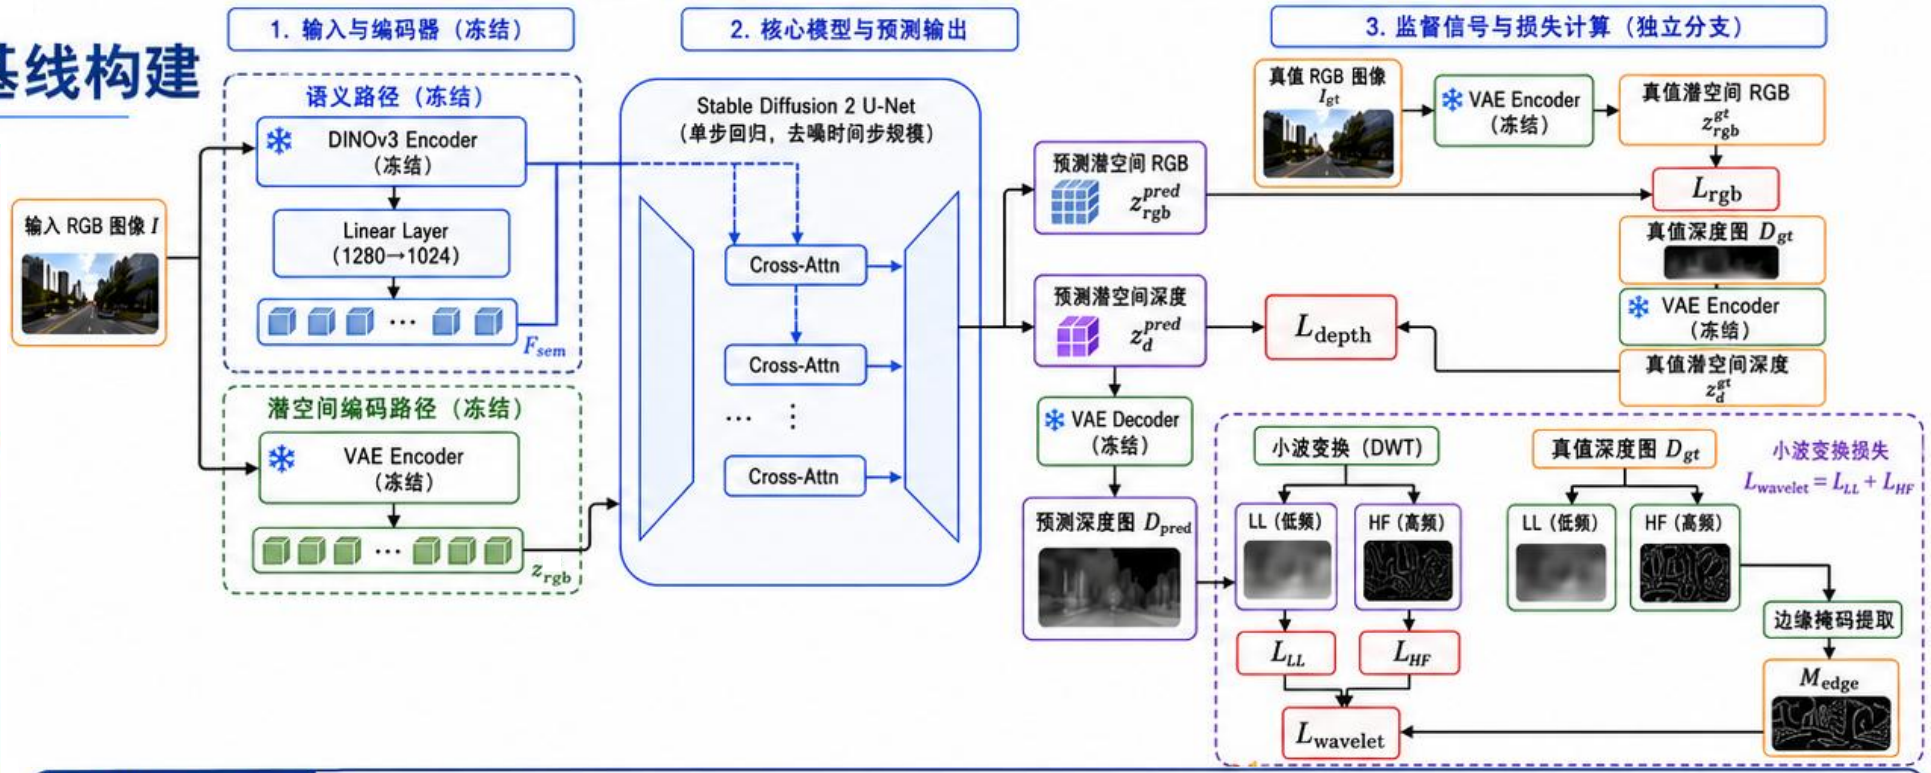
- 将透明物体法线估计改为像素级深度估计；
- 训练标签由法线 N^* 替换为深度 D^*。

② 监督信号潜空间化

- RGB图像与深度真值均经冻结VAE编码；
- 构造真值RGB潜表示 z^*_{rgb} 与真值深度潜表示 z^*_d；
- DINOv3与VAE保持冻结，仅训练投影层与U-Net。

③ 训练目标重构

- 主任务约束**深度潜表示**回归；
- 保留**RGB辅助重建**，稳定共享U-Net；
- 在解码深度图上加入**小波正则**，补充结构与边缘约束。



基线损失函数

$$L_{base} = L_{depth} + \lambda_{rgb} L_{rgb} + \lambda_{wv} L_{wavelet}$$

L_{depth}

$$L_{depth} = \| z^{pred}_d - z^{gt}_d \|^2_2$$

约束预测深度潜表示与真值深度潜表示一致。

L_{rgb}

$$L_{rgb} = \| z^{pred}_{rgb} - z^{gt}_{rgb} \|^2_2$$

保留RGB潜空间重建能力，稳定共享U-Net训练。

$L_{wavelet}$

$$L_{wavelet} = L_{LL} + L_{HF}$$

$$L_{LL} = \| LL(D_{pred}) - LL(D_{gt}) \|_1$$

$$L_{HF} = \| M_{edge} \odot (HF(D_{pred}) - HF(D_{gt})) \|_1$$

在解码深度图上的低频结构与边缘高频细节。

本文工作

实验设置与数据集



ClearGrasp
透明物体合成数据集
训练样本：45454

提供透明物体 RGB 与深度监督，
覆盖抓取相关透明场景。



TransNormal-Synthetic
透明实验器皿合成数据集
训练样本：4000

提供实验室玻璃器皿场景监督，
强调折射与几何结构。



Hypersim
通用室内场景数据集
训练样本：39648

提供大规模室内几何监督，
增强通用场景先验。



Virtual KITTI 2
通用户外场景数据集
训练样本：25780

补充室外道路场景几何信息，
缓解透明场景过拟合。

训练数据混合比例



ClearGrasp	35%
TransNormal-Synthetic	15%
Hypersim	45%
Virtual KITTI 2	5%

透明物体专用数据与通用场景数据混合训练，用于兼顾透明目标感知与整体几何泛化能力。

主要训练配置

基础模型：	Stable Diffusion 2.1-base	训练步数：	15000
语义编码：	DINOv3 ViT-H/16+	保存与验证：	每 1000 步一次
训练模块：	U-Net、语义投影层、辅助解码器	混合精度：	bf16
冻结模块：	VAE、DINOv3	批量设置：	单卡 2，梯度累积 8， 2 卡 A100 40G， 全局 batch size = 32
预测方式：	固定 t=1 单步回归	数据增强：	水平翻转 p = 0.5
输入分辨率：	576 × 768	主要损失权重：	λ_{rgb} = 1.0，λ_{depth} = 1.0， λ_{wv} = 0.1，λ_{rae} = 5×10^{-5}， λ_{rec} = 0.5
优化器：	AdamW		
基础学习率：	3 × 10^{-5}		
权重衰减：	1 × 10^{-2}		

验证数据集



ClearGrasp
408 张
合成透明场景测试集。



TransNormal-Synthetic
395 张
透明实验器皿保留测试集。



ClearPose
120 张
真实透明物体场景；未参与训练，
用于零样本泛化评估。

实验分析

实验设置与数据集



ClearGrasp
透明物体合成数据集
训练样本：45454

提供透明物体 RGB 与深度监督，
覆盖抓取相关透明场景。



TransNormal-Synthetic
透明实验器皿合成数据集
训练样本：4000

提供实验室玻璃器皿场景监督，
强调折射与几何结构。



Hypersim
通用室内场景数据集
训练样本：39648

提供大规模室内几何监督，
增强通用场景先验。



Virtual KITTI 2
通用户外场景数据集
训练样本：25780

补充室外道路场景几何信息，
缓解透明场景过拟合。

训练数据混合比例



ClearGrasp	35%
TransNormal-Synthetic	15%
Hypersim	45%
Virtual KITTI 2	5%

透明物体专用数据与通用场景数据混合训练，用于兼顾透明目标感知与整体几何泛化能力。

主要训练配置

基础模型：	Stable Diffusion 2.1-base	训练步数：	15000
语义编码：	DINOv3 ViT-H/16+	保存与验证：	每 1000 步一次
训练模块：	U-Net、语义投影层、辅助解码器	混合精度：	bf16
冻结模块：	VAE、DINOv3	批量设置：	单卡 2，梯度累积 8， 2 卡 A100 40G， 全局 batch size = 32
预测方式：	固定 t=1 单步回归	数据增强：	水平翻转 p = 0.5
输入分辨率：	576 × 768	主要损失权重：	$\lambda_{rgb} = 1.0$，$\lambda_{depth} = 1.0$， $\lambda_{wv} = 0.1$，$\lambda_{rae} = 5\times10^{-5}$， $\lambda_{rec} = 0.5$
优化器：	AdamW		
基础学习率：	3×10^{-5}		
权重衰减：	1×10^{-2}		

验证数据集



ClearGrasp
408 张
合成透明场景测试集。



TransNormal-Synthetic
395 张
透明实验器皿保留测试集。



ClearPose
120 张
真实透明物体场景；未参与训练，
用于零样本泛化评估。

实验分析

本文方法与基线方法对比

验证集定量对比@15000

验证集	方法	T/G AbsRel↓	T/G RMSE↓	T/G δ1↑
ClearGrasp	基线	0.0310/0.0208	**0.0203**/0.0186	0.9992/0.9992
	本文方法	**0.0303/0.0173**	0.0209/**0.0168**	**0.9994/0.9995**
TransNormal-Synthetic	基线	**0.0356/0.0300**	3543.2/3225.3	0.9899/0.9924
	本文方法	0.0379/0.0337	**3524.5/3223.3**	**0.9907/0.9926**
ClearPose	基线	0.2603/0.2420	335.9/443.4	0.5810/0.5879
	本文方法	**0.1820/0.1847**	**254.5/391.4**	**0.7533/0.7505**

* T 表示透明物体有效区域，G 表示全图有效区域。

* RMSE 数值受深度原始尺度影响，不同验证集之间不直接横向比较。

- ClearGrasp: **全图AbsRel与RMSE均有下降**；透明区域AbsRel略微下降，RMSE小幅波动。
- TransNormal-Synthetic: **RMSE与δ_1**略优于基线，但AbsRel相较于基线略有升高。
- ClearPose: 本文方法在透明区域和全图的各个指标均**明显优于基线**

相较基线，本文方法在真实透明物体场景中具有良好的性能和泛化性

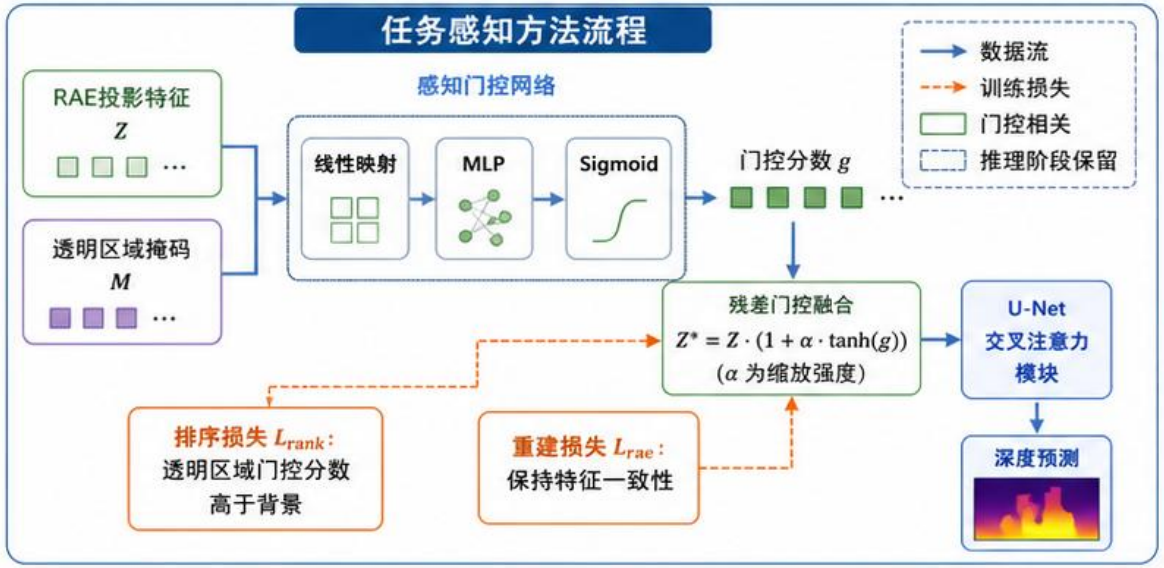
AbsRel $AbsRel = \frac{1}{|\Omega|}\sum_{p\in\Omega}\frac{|d_p-\hat{d}_p|}{d_p}$ 平均相对误差，反映预测深度相对真值的偏差。

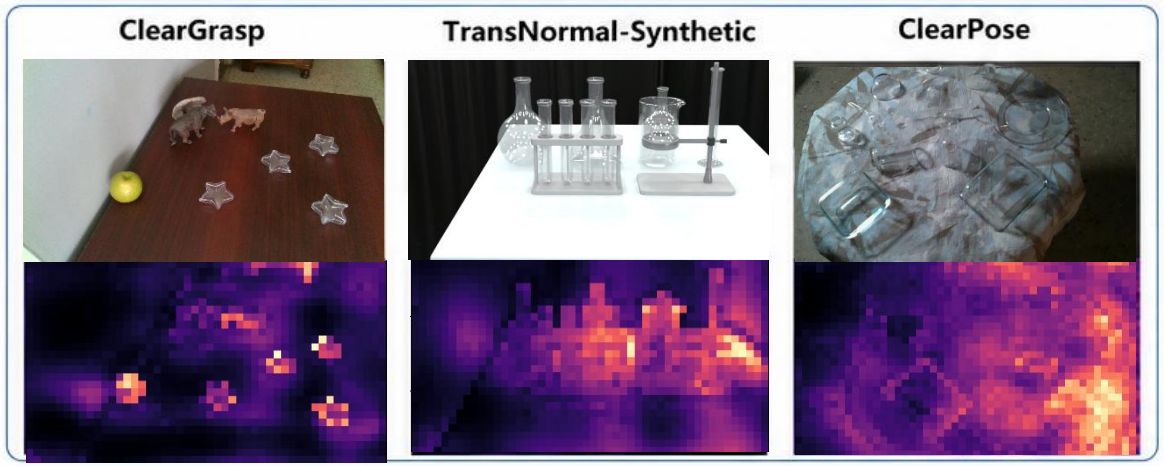
RMSE $RMSE = \sqrt{\frac{1}{|\Omega|}\sum_{p\in\Omega}(\hat{d}_p-d_p)^2}$ 均方根误差，反映深度误差幅度。

δ_1 $\delta_1 = \frac{1}{|\Omega|}\sum_{p\in\Omega}1[\max(\frac{\hat{d}_p}{d_p},\frac{d_p}{\hat{d}_p})<1.25]$ 阈值精度，统计满足误差比例约束的像素占比。

实验分析

透明区域注意力引导实验





任务感知方法全图指标对比

验证集	基线方法 AbsRel / δ1	本文方法 AbsRel / δ1	任务感知方法 AbsRel / δ1
ClearGrasp	0.0208 / 0.9992	**0.0173 / 0.9995**	0.0197 / 0.9988
TransNormal-Synthetic	**0.0300** /0.9924	0.0337 /**0.9926**	0.0363 / 0.9924
ClearPose	0.2420 / 0.5879	**0.1847 / 0.7505**	0.2577 / 0.5694

因果干预实验：透明区域AbsRel

设置	全图G	透明T
无门控	0.0381	0.0651
理想门控	0.0392	0.0671
注意力干预	0.0397	0.0685

* 理想门控指直接使用真实透明区域掩码构造门控信号，用于检验透明区域注意力增强的上限影响。

注意力质量与透明区域误差相关性

统计项	Pearson r	Spearman ρ
透明Token注意力占比	-0.065	0.106
Top-20透明质量占比	-0.080	0.055
查询熵均值	0.097	-0.134
查询Top-1质量均值	-0.087	0.111

* 相关系数绝对值整体较低，未形成稳定线性或单调关系。

- 任务感知方法使透明区域注意力更集中，但三组验证集均未超过本文方法。
- 理想门控和注意力干预均未降低透明区域AbsRel，说明透明区域注意力增强本身不足以带来精度提升。
- 相关性统计进一步表明，注意力集中度与透明区域误差之间缺乏稳定对应关系。

后续展望

工作总结与后续方向

主要贡献

构建透明物体深度估计基线



将TransNormal 单步扩散框架从透明物体法线估计**迁移到深度估计任务**,完成深度监督信号、损失函数与评估协议的建立。

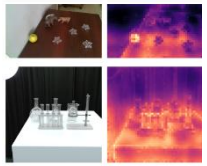
提出DINO条件特征映射方法



针对DINO→U-Net投影层，**引入RAE编码器、LayerNorm归一化与Scaling 缩放**,增强条件特征的结构保持与数值适配能力。

完成多层次实验与机制分析

验证集	方法	T/G AbsRel↓	T/G RMSE↓	T/G δ1↑
ClearGrasp	基线	0.0310/0.0208	**0.0203**/0.0186	0.9992/0.9992
	本文方法	**0.0303/0.0173**	0.0209/**0.0168**	**0.9994/0.9995**
TransNormal-Synthetic	基线	**0.0356/0.0300**	3543.2/3225.3	0.9899/0.9924
	本文方法	0.0379/0.0337	**3524.5/3223.3**	**0.9907/0.9926**
ClearPose	基线	0.2603/0.2420	335.9/443.4	0.5810/0.5879
	本文方法	**0.1820/0.1847**	**254.5/391.4**	**0.7533/0.7505**



在透明物体相关数据集上完成**定量对比、消融实验、降维可视化和注意力相关分析**，在真实透明场景中展现出明显的提升效果。

不足与展望

部分数据集上收益不稳定

尽管在零样本的ClearPose数据集上取得了一定提升，但在两个合成数据集上的性能存在一定波动，且零样本数据集的验证范围有待进一步扩大

训练规模与超参数搜索受限

考虑到资源和时间有限，训练步数、模块权重、投影结构及数据混合比例仍有进一步搜索空间，可能影响最优性能的进一步发掘。

探索面向透明物体边界与上下文的约束

根据目前的分析结论，仍可围绕透明边界、支撑面及邻近上下文区域设计更专门的几何约束与建模策略,以进一步提升几何一致性与泛化性能。

结论

针对透明物体的深度估计场景，本毕设对稠密语义特征到扩散模型的注入过程提出了以RAE编码器结合LayerNorm和Scaling的方法，并取得了较好的效果，尤其在真实场景数据上提升更明显。进一步分析说明，主要误差源于透明物体边界及周围，单纯增强透明区域注意力不能直接提升模型表现。

准备学术汇报是对思路的整理，

做好学术报告是研究生的必备技能！